

ШИНЖЛЭХ УХААН ТЕХНОЛОГИЙН ИХ
СУРГУУЛЬ
Мэдээлэл, Холбооны Технологийн Сургууль



Цогбадрах Болортуяа

**Хүйсийн болон нийгмийн тэгш,
хүртээмжтэй байдлыг хангахад
чиглэсэн хиймэл оюунт чатбот
хөгжүүлэх нь**

БАКАЛАВРЫН ТӨГСӨЛТИЙН АЖИЛ

Улаанбаатар хот

ШИНЖЛЭХ УХААН ТЕХНОЛОГИЙН ИХ
СУРГУУЛЬ
Мэдээлэл, Холбооны Технологийн Сургууль

Компьютерын ухааны салбар

Хүйсийн болон нийгмийн тэгш,
хүртээмжтэй байдлыг хангахад
чиглэсэн хиймэл оюунт чатбот
хөгжүүлэх нь

Мэргэжлийн индекс: ???

Мэргэжил: Компьютерын ухаан

Удирдагч: Дэд проф. PhD. Б.Туяацэцэг

Зөвлөгч: Магистр Э.Батцэцэг

Гүйцэтгэгч: Ц.Болортуяа

Улаанбаатар хот

2026 он 6 сар

Батлав. Компьютерын ухааны салбарын эрхлэгч:

..... /Проф. PhD. А.Хүдэр/

Удирдагч:

..... /Дэд проф. PhD. Б.Туяацэцэг/

ТӨГСӨЛТИЙН АЖЛЫН ТӨЛӨВЛӨГӨӨ

Сэдэв: "Хүйсийн болон нийгмийн тэгш, хүртээмжтэй
байдлыг хангахад чиглэсэн хиймэл оюунт чатбот
хөгжүүлэх нь"

№	Ажлын бүлэг, хэсгийн нэр	Эзлэх хувь	Дуусах хугацаа
1	Удиртгал	5%	2026-02-23
2	Онолын хэсэг	25%	2026-02-28
3	Судалгааны хэсэг	30%	2026-03-04
4	Төслийн хэсэг	30%	2026-04-01
5	Дүгнэлт	10%	2026-04-29

Төлөвлөгөөг боловсруулсан оюутан: /Ц.Болортуяа/

ТӨГСӨЛТИЙН АЖЛЫН ЯВЦ

№	Хийж гүйцэтгэсэн ажил	Биелсэн хугацаа	Удирдагчийн гарын үсэг
1	Удиртгал	2026-03-04	
2	Онолын хэсэг	2026-03-04	
3	Судалгааны хэсэг	2026-03-04	
4	Төслийн хэсэг	2026-04-01	
5	Дүгнэлт	2026-04-29	

Ажлын товч дүгнэлт

.....

.....

.....

.....

.....

.....

.....

Удирдагч: /Дэд проф. PhD. Б.Туяацэцэг/

ЗӨВШӨӨРӨЛ

Оюутан Ц.Болортуяагын бичсэн төгсөлтийн ажлыг УШК-д
хамгаалуулахаар тодорхойлов.

Салбарын эрхлэгч: /Проф. PhD. А.Хүдэр/

ШИНЖЛЭХ УХААН ТЕХНОЛОГИЙН ИХ СУРГУУЛЬ

Мэдээлэл, Холбооны Технологийн Сургууль

ШҮҮМЖИЙН ХУУДАС

Компьютерын ухааны салбарын салбарын төгсөх курсийн оюутан Ц.Болортуяа-
н "Хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлыг хангахад чиглэсэн
хиймэл оюунт чатбот хөгжүүлэх нь" сэдэвт төгсөлтийн ажлын шүүмж.

1. Төслөөр дэвшүүлсэн асуудал, үүнтэй холбоотой онолын материал ун-
шиж судалсан байдал. Энэ талаар хүмүүсийн хийсэн судалгаа, түүний
үр дүнг уншиж тусгасан эсэх.

.....
.....
.....
.....
.....
.....
.....

2. Төслийн ерөнхий агуулга. Шийдсэн зүйлүүд, хүрсэн үр дүн. Өөрийн
санааг гарган, харьцуулалт хийн, дүгнэж байгаа чадвар.

.....
.....
.....
.....
.....
.....
.....

3. Эмх цэгцтэй, стандарт хангасан өөрөөр хэлбэл диплом бичих шаардла-
гуудыг биелүүлсэн эсэх. Төсөлд анзаарагдсан алдаанууд, зөв бичгийн
болон өгүүлбэр зүйн гэх мэт /Хуудас дугаарлагдаагүй, зураг хүснэг-
тийн дугаар болон тайлбар байхгүй, шриффт хольсон, хувилсан зүйл
ихээр оруулсан/.

.....
.....
.....
.....
.....
.....
.....

4. Төслөөр орхигдуулсан болон дутуу болсон зүйлүүд. Цаашид анхаарах хэрэгтэй зүйлүүд.

.....
.....
.....
.....
.....
.....
.....

5. Төслийн талаар онцолж тэмдэглэх зүйлүүд.

.....
.....
.....
.....
.....
.....
.....

6. Ерөнхий оноо. (5 оноо)

.....

Шүүмж бичсэн: /.../

Ажлын газар:

Хаяг (Утас)

Зохиогч эрхийн хамгаалал

Миний бие Ц.Болортуяа, "Хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлыг хангахад чиглэсэн хиймэл оюунт чатбот хөгжүүлэх нь" сэдэвт энэ ажил нь минийх бөгөөд дараахыг нотолж байна. Үүнд:

- Горилогч энэ ажлыг тус сургуулиас боловсролын зэрэг авахаар бүхэлд нь буюу голлон хийсэн болно.
- Энэ ажлын аль нэг хэсгийг тус сургуульд эсвэл өөр байгууллагад боловсролын зэрэг, мэргэшил авахаар өмнө нь илгээсэн бол түүнийгээ тодорхой заасан болно.
- Бусад хүмүүсийн хэвлүүлсэн ажлаас зөвлөгөө авсан бол түүнийгээ үндэслэсэн болно.
- Бусад хүмүүсийн ажлаас ишлэл хийхдээ гол эх үүсвэрийг нь заасан болно.
- Миний ажилд тусалсан голлох бүх эх үүсвэрт талархаж байна.
- Ажлыг бусадтай хамтарсан бол алийг нь бусад хүмүүс хийсэн болохыг тодорхой заасан болно.

Гарын үсэг: _____

Огноо: _____

ШИНЖЛЭХ УХААН ТЕХНОЛОГИЙН ИХ СУРГУУЛЬ

Мэдээлэл, Холбооны Технологийн Сургууль

Хураангуй

Хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлыг хангахад чиглэсэн хиймэл оюунт чатбот хөгжүүлэх нь

Ц.Болортуяа
bolortuyats415@gmail.com

Түлхүүр үгс: хиймэл оюун ухаан, чатбот, хүйсийн тэгш байдал, нийгмийн хүртээмжтэй байдал, RAG, NLP, LLM, мэдлэгийн сан

Хүйсийн болон нийгмийн тэгш байдалтай холбоотой асуудлууд нийгмийн олон түвшинд ажиглагдсаар байна. Тухайлбал өсвөр насны хүүхдүүдийн дунд нэгнээ ялгаварлан гадуурхах, дээрэлхэх, хөгжлийн бэрхшээлтэй иргэд амьдрах, ажиллах орчин дутмаг байхын зэрэгцээ ажлын байр, боловсролын орчин болон нийгмийн бусад хүрээнд тэгш бус харилцаа байсаар байна. Ийм асуудлууд нь зөвхөн хувь хүний сэтгэлзүй, харилцаанд нөлөөлөөд зогсохгүй нийгмийн оролцоо, тэгш боломж, хүртээмжтэй орчны хөгжилд сөргөөр нөлөөлдөг.

Эдгээр нөхцөлд иргэд, ажилтан, суралцагчид эрх тэгш байдал, харилцан хүндлэл, хүртээмжтэй орчны талаарх зөв ойлголттой байх нь чухал ач холбогдолтой. Гэвч энэ төрлийн мэдээлэл нь ихэвчлэн олон эх сурвалжид тархсан, урт хэлбэртэй, заримдаа мэргэжлийн хэллэгтэй баримт бичигт агуулагддаг тул хэрэглэгчид шаардлагатай мэдээллээ богино хугацаанд олж авах, зөв ойлгох, хэрэглэхэд хүндрэлтэй байдаг.

Нөгөө талаас сүүлийн жилүүдэд байгалийн хэл боловсруулалт(NLP) болон том хэлний загвар(LLM)-т суурилсан хиймэл оюун ухааны шийдлүүд өргөн хөгжиж, мэдээлэл хүргэх, асуултад хариулах, хэрэглэгчтэй харилцах чиглэлээр олон салбарт амжилттай ашиглагдаж байна. Ийм боломжийг хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлын талаарх мэдээлэл түгээхэд ашигласнаар хэрэглэгчдэд илүү ойлгомжтой, хүртээмжтэй, харилцан ярианд суурилсан үйлчилгээ үзүүлэх боломжтой.

Иймээс энэхүү дипломын ажил нь хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлыг хангахад чиглэсэн хиймэл оюун ухаант чатбот системийг

судалж, түүний архитектур, мэдлэгийн сан, баримтад тулгуурласан хариулт
үүсгэх аргачлалд суурилсан шийдлийг боловсруулахад чиглэж байна.

Талархал

Энэхүү дипломын ажлыг гүйцэтгэх явцад үнэтэй зөвлөгөө, цаг зав, дэмжлэг үзүүлсэн бүх хүмүүст гүн талархал илэрхийлье.

Юуны өмнө миний бие энэхүү судалгааны сэдвийг сонгох, асуудлыг тодорхойлох, аргачлалыг оновчтой болгох, чанарын стандарт хангуулах гээд бүх үе шатанд тууштай зөвлөж, чиглүүлсэн удирдагч багш **Дэд проф. PhD. Б.Туяацэцэг**-д гүн талархал илэрхийлж байна.

Зөвлөгчийн хувиар техникийн зөвлөгөө, мэргэжлийн хэлэлцүүлэг хийж, ажлын нарийн чанарт онцгой анхаарал хандуулсан зөвлөгч багш **Магистр Э.Батцэцэг**-д мөн маш их талархаж байна.

Шинжлэх Ухаан Технологийн Их Сургуулийн **Мэдээлэл, Холбооны Технологийн Сургууль** болон **Компьютерын ухааны салбар**-ын багш нар, ялангуяа салбарын эрхлэгч **Проф. PhD. А.Хүдэр**-д үзүүлсэн дэмжлэгт талархал илэрхийлье. Мөн дөрвөн жилийн хугацаанд авсан мэдлэг боловсролыг бий болгож өгсөн профессор багш нар, өдөр тутмын суралцах орчинг бүрдүүлсэн оюутан анги хамт олондоо талархаж байна.

Эцэст нь судалгааны бүх явцад ёс суртахуун, сэтгэл санааны дэмжлэг үзүүлсэн гэр бүлийн гишүүд, найз нөхөддөө гүн талархал илэрхийлье.

Товчилсон үгс

AI	Artificial Intelligence
API	Application Programming Interface
BERT	Bidirectional Encoder Representations from Transformers
BGE	BAAI General Embedding
CPU	Central Processing Unit
DPR	Dense Passage Retrieval
EU	European Union
FAQ	Frequently Asked Questions
GPT	Generative Pre-trained Transformer
GPU	Graphics Processing Unit
HR	Human Resources
HTTP	HyperText Transfer Protocol
IDE	Integrated Development Environment
ILO	International Labour Organization
IR	Information Retrieval
JSON	JavaScript Object Notation
LLM	Large Language Model
MoE	Mixture of Experts
MRR	Mean Reciprocal Rank
nDCG	normalized Discounted Cumulative Gain
NIST	National Institute of Standards and Technology
NLP	Natural Language Processing
NSO	National Statistical Office (Үндэсний статистикийн хороо)
PDF	Portable Document Format
RAG	Retrieval-Augmented Generation
RAGAS	Retrieval Augmented Generation ASsessment
RAI	Responsible AI
REST	REpresentational State Transfer
RLHF	Reinforcement Learning from Human Feedback
SDK	Software Development Kit
SQL	Structured Query Language
T5	Text-to-Text Transfer Transformer
UI	User Interface
UN	United Nations
UNESCO	United Nations Educational, Scientific and Cultural Organization
UNICEF	United Nations International Children's Emergency Fund
UX	User Experience
WEF	World Economic Forum
WHO	World Health Organization
ХЭҮК	Хүний Эрхийн Үндэсний Комисс

Удиртгал

Орчин үеийн нийгэмд хүйсийн болон нийгмийн тэгш байдал, хүртээмжтэй орчин нь хүний эрх, боловсрол, хөдөлмөр эрхлэлт, байгууллагын соёл болон нийгмийн хөгжилтэй шууд холбоотой чухал асуудлын нэг болж байна. Хүн бүр ялгаатай байдлаасаа үл хамааран мэдээлэл авах, суралцах, ажиллах, нийгмийн амьдралд оролцох тэгш боломжтой байх нь хүртээмжтэй нийгмийг бүрдүүлэх үндэс юм.

Гэвч хүйсийн хэвшмэл ойлголт, ялгаварлан гадуурхалт, нийгмийн тэгш бус байдал, хүртээмжгүй орчин зэрэг асуудлууд өнөөг хүртэл тодорхой хэмжээнд оршсоор байна. Эдгээр асуудал нь хувь хүний эрх, боломжид нөлөөлөхөөс гадна байгууллага, боловсролын орчин болон нийгмийн хөгжилд сөрөг нөлөө үзүүлдэг. Иймээс иргэд, ажилтан, суралцагчид хүйсийн болон нийгмийн тэгш байдал, харилцан хүндлэл, хүртээмжтэй орчны талаарх зөв ойлголттой байх шаардлагатай.

Энэ төрлийн мэдээлэл нь ихэвчлэн хууль эрх зүйн баримт бичиг, бодлогын баримт бичиг, гарын авлага, сургалтын материал зэрэг олон эх сурвалжид тархсан байдаг. Мөн зарим мэдээлэл нь урт, мэргэжлийн нэр томьёо ихтэй байдаг тул хэрэглэгч шаардлагатай мэдээллээ богино хугацаанд олж авах, ойлгох, хэрэглэхэд хүндрэлтэй байдаг.

Сүүлийн жилүүдэд байгалийн хэл боловсруулалт (NLP) болон том хэлний загвар (LLM)-т суурилсан хиймэл оюун ухааны технологи эрчимтэй хөгжиж, асуултад хариулах, мэдээлэл хүргэх, хэрэглэгчтэй харилцах чиглэлээр өргөн ашиглагдаж байна. Гэсэн хэдий ч зөвхөн том хэлний загварт тулгуурласан систем нь эх сурвалжгүй эсвэл буруу хариулт үүсгэх эрсдэлтэй байдаг. Иймээс мэдлэгийн сангаас холбогдох мэдээллийг хайж, баримтад тулгуурлан хариулт үүсгэдэг RAG (Retrieval-Augmented Generation) архитектур нь илүү найдвартай шийдэл юм.

Иймд энэхүү дипломын ажил нь хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлын талаарх мэдээллийг хэрэглэгчдэд ойлгомжтой, хүртээмжтэй байдлаар хүргэх RAG суурьтай хиймэл оюун ухаант чатбот системийг судалж, боловсруулахад чиглэж байна.

Зорилго

Энэхүү дипломын ажлын зорилго нь хэрэглэгчийн асуултад хүйсийн болон нийгмийн тэгш байдал, хүртээмжтэй орчны талаарх мэдээллийг баримтад тулгуурлан тайлбарлах, мэдлэгийн сангаас холбогдох мэдээллийг хайж татах RAG (Retrieval-Augmented Generation) суурьтай хиймэл оюун ухаанд суурилсан чатбот системийг боловсруулахад оршино.

Зорилтууд

Дипломын ажлын зорилгыг хэрэгжүүлэхийн тулд дараах зорилтуудыг дэвшүүлэв.

1. Хүйсийн болон нийгмийн тэгш байдал, хүртээмжтэй байдлын онолын үндсийг судлах
2. AI чатбот, байгалийн хэл боловсруулалт (NLP) болон том хэлний загвар (LLM) технологийн талаар судалгаа хийх
3. Баримтад тулгуурласан хариулт үүсгэх RAG архитектурын зарчмыг судлах
4. Чатбот системийн архитектур болон мэдлэгийн сангийн бүтцийг боловсруулах
5. Хэрэглэгчийн асуултад хариулах чатбот системийн прототипийг хэрэгжүүлэх
6. Системийн ажиллагааг туршилтын асуултын багц ашиглан үнэлэх

*Хүйс, нас, гарал үүсэл, нийгмийн байдлаасаа үл
хамааран тэгш боломж, хүндлэлтэй харилцааг хүсэн
хүлээгч бүх хүнд зориулав.*

Гарчиг

Зохиогч эрхийн хамгаалал	i
Хураангуй	ii
Талархал	iv
Товчилсон үгс	v
Удиртгал	vi
1 Онолын үндэс	1
1.1 Бүлгийн зорилго ба хамрах хүрээ	1
1.2 Хүйсийн болон нийгмийн тэгш байдлын онолын үндэс	1
1.2.1 Хүйсийн тэгш байдлын ойлголт	1
1.2.2 Нийгмийн хүртээмжтэй байдлын ойлголт	2
1.2.3 Ялгаварлан гадуурхалт, дээрэлхэлт ба нийгмийн ач хол- богдол	2
1.3 Хиймэл оюун ухаан ба байгалийн хэл боловсруулалт	3
1.3.1 Хиймэл оюун ухааны үндсэн ойлголт	3
1.3.2 Байгалийн хэл боловсруулалт	3
1.3.3 Трансформер архитектур ба том хэлний загвар	4
1.4 Чатбот систем ба баримтад тулгуурласан хариулт үүсгэх ар- гачлал	5
1.4.1 Чатбот системийн ойлголт ба ангилал	5
1.4.2 Чатбот системийн үндсэн бүтэц	7
1.4.3 Retrieval-Augmented Generation (RAG)	7
1.5 Хариуцлагатай AI ба хүртээмжтэй харилцааны зарчим	8
1.5.1 Хариуцлагатай AI-ийн үндсэн ойлголт	8
1.5.2 Ялгаварлан гадуурхахгүй харилцаа ба хүртээмжтэй ди- зайн	10
1.6 Хууль эрх зүй ба бодлогын орчин	10
1.6.1 Монгол Улсын эрх зүйн зохицуулалт	10
1.6.2 Олон улсын зарчим ба стандарт	10
1.7 Бүлгийн дүгнэлт	11
2 Судалгаа ба шийдлийн загвар	12
2.1 Бүлгийн зорилго	12
2.2 Ижил төстэй системүүдийн судалгаа ба харьцуулалт	12
2.2.1 Харьцуулалтын шалгуур	12
2.2.2 Харьцуулалтын хүснэгт	13

2.2.3	Судалгааны дүгнэлт	13
2.3	Системийн хамрах хүрээ	13
2.4	Системийн ерөнхий архитектур	15
2.5	Системийн үндсэн функцууд	15
2.6	Системийн шаардлагын тодорхойлолт	16
2.6.1	Функциональ шаардлага	16
2.6.2	Функциональ бус шаардлага	16
2.7	Мэдлэгийн сан бүрдүүлэх судалгаа	16
2.7.1	Эх сурвалжийн төрөл	17
2.7.2	Баримт боловсруулах үе шат	17
2.8	RAG архитектурын сонголт ба параметрийн судалгаа	17
2.8.1	Хэсэглэлтийн стратеги	18
2.8.2	Embedding ба вектор хайлт	19
2.8.3	Top- k ба дахин эрэмбэлэлт	20
2.8.4	Prompt загвар ба эх сурвалжийн ишлэл	20
2.9	Хариуцлагатай AI ба хамгаалалтын зохицуулалт	20
2.10	Туршилт ба үнэлгээний аргачлал	21
2.10.1	Retrieval чанарын үнэлгээ	21
2.10.2	Хариултын чанарын үнэлгээ	22
2.10.3	Хэрэглэгчийн үнэлгээ	22
2.11	Бүлгийн дүгнэлт	22
3	Системийн зохиомж, диаграм	24
3.1	Системийн ерөнхий архитектур	24
3.2	Архитектурын сонголтын үндэслэл	24
3.2.1	Технологийн стек ба сонголтын үндэслэл	26
3.3	Өгөгдлийн сангийн бүтэц	26
3.4	RAG pipeline-ийн параметрууд	28
3.5	Класс диаграм	31
3.6	Дарааллын диаграм	32
3.6.1	Асуулт хариултын дарааллын диаграм	32
3.6.2	Баримт бичиг оруулах дарааллын диаграм	32
3.7	Байршуулах болон үйл ажиллагааны диаграм	34
3.7.1	Системийг байршуулах диаграм	34
3.7.2	Баримт бичиг боловсруулах үйл ажиллагааны диаграм	34
3.8	Аюулгүй байдал ба нууцлалын зохиомж	35
3.9	Бүлгийн дүгнэлт	36
4	Системийн хэрэгжүүлэлт, туршилт ба үр дүн	37
4.1	Бүлгийн зорилго ба хамрах хүрээ	37
4.2	Хөгжүүлэлтийн орчин	37
4.3	Системийн модулийн бүтэц	37
4.4	API endpoint-ийн хэрэгжилт	37
4.5	RAG pipeline-ийн хэрэгжилт	39
4.6	Чатын замчилгаа ба аюулгүй байдлын шалгуур	40
4.7	Мэдлэгийн санд оруулсан баримтууд	42
4.8	Туршилтын аргачлал	42
4.9	Retrieval-ийн чанарын үр дүн	44

4.10	Generation-ийн чанарын үр дүн	44
4.11	Системийн гүйцэтгэлийн үзүүлэлт	45
4.12	Crisis detection-ийн үнэлгээ	47
4.13	Хэрэглэгчийн санал хүсэлт	47
4.14	Үр дүнгийн хэлэлцүүлэг	48
4.15	Бүлгийн дүгнэлт	49
4.16	Ерөнхий дүгнэлт	49
A	API ба тохиргооны жишээ	51
A.1	Чатын API-ийн жишээ	51
A.2	Орчны хувьсагчийн жишээ	52
A.3	Туршилтын асуултын жишээ багц	52
A.4	Эх кодын байршил	53
	Ном зүй	54

Зургийн жагсаалт

3.1	Системийн ерөнхий архитектур	25
3.2	Класс диаграм	31
3.3	Асуулт хариултын дарааллын диаграм	32
3.4	Баримт бичиг оруулах дарааллын диаграм	33
3.5	Системийг байршуулах диаграм	34
3.6	Баримт бичиг боловсруулах үйл ажиллагааны диаграм	35
4.1	Чатын асуултын урсгал диаграм	41
4.2	Offline ingestion урсгал	43

Хүснэгтийн жагсаалт

1.1	Том хэлний загваруудын харьцуулалт	5
1.2	Чатбот системийн ангилалын харьцуулалт	6
1.3	Хариуцлагатай AI-ийн зарчмууд	9
2.1	Ижил төстэй системүүдийн харьцуулалт	14
2.2	Хэсэглэлтийн стратегийн харьцуулалт	18
2.3	Embedding загваруудын харьцуулалт	19
2.4	RAG системийн үнэлгээний хэмжүүрүүд	21
3.1	Системийн технологийн стек	27
3.2	Өгөгдлийн сангийн бүрэлдэхүүн хэсгүүд	28
3.3	RAG pipeline-ийн үндсэн параметрууд	29
4.1	Хөгжүүлэлтэд ашигласан технологи	38
4.2	Backend-ийн модулийн бүтэц	38
4.3	API endpoint-ийн жагсаалт	39
4.4	Чатын замчилгааны логик	40
4.5	Корпусын статистик	42
4.6	Туршилтын асуултын багц	43
4.7	Retrieval-ийн чанарын үр дүн	44
4.8	Generation-ийн чанарын үр дүн	45
4.9	Системийн гүйцэтгэлийн үзүүлэлт	46
4.10	Crisis detection-ийн үнэлгээ	47
4.11	Хэрэглэгчийн санал хүсэлт	48
A.1	Туршилтын асуултын жишээ	53

БҮЛЭГ 1

Онолын үндэс

1.1 Бүлгийн зорилго ба хамрах хүрээ

Энэхүү бүлэгт хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлын тухай үндсэн ойлголт, тэдгээрийн нийгэм дэх ач холбогдол, мөн эдгээр асуудалтай холбоотой мэдээллийг хэрэглэгчдэд ойлгомжтой хэлбэрээр хүргэхэд ашиглагдах хиймэл оюун ухаанд суурилсан чатбот системийн онолын үндсийг авч үзнэ. Үүний хүрээнд хүйсийн тэгш байдал, нийгмийн хүртээмжтэй байдал, ялгаварлан гадуурхалт ба гадуурхлын нийгмийн үр дагавар, байгалийн хэл боловсруулалт(Natural Language Processing), том хэлний загвар(Large Language Model), Retrieval-Augmented Generation (RAG) аргачлал болон хариуцлагатай AI-ийн үндсэн зарчмуудыг тайлбарлана. Мөн эдгээр ойлголтуудыг Монгол Улсын хууль эрх зүйн орчин болон олон улсын зарчимтай уялдуулан авч үзнэ.

1.2 Хүйсийн болон нийгмийн тэгш байдлын онолын үндэс

1.2.1 Хүйсийн тэгш байдлын ойлголт

Хүйсийн тэгш байдал гэдэг нь хүйсээс үл хамааран хүн бүр эрх, боломж, оролцооны нөхцөлөөр тэгш хангагдахыг хэлнэ. Энэ ойлголт нь зөвхөн хууль эрх зүйн тэгш байдлаар хязгаарлагдахгүй бөгөөд боловсрол, хөдөлмөр эрхлэлт, нийгмийн оролцоо, шийдвэр гаргалт, мэдээлэлд хүрэх боломж зэрэг өргөн хүрээний асуудлыг хамардаг [1]. Хүйсийн тэгш байдлыг хангах нь хувь хүний эрхийг хамгаалахаас гадна нийгмийн шударга байдал, тогтвортой хөгжил, эдийн засгийн оролцоог дэмжих үндэс болдог.

Практикт хүйсийн тэгш бус байдал нь ил тод болон далд хэлбэрээр илэрч болзошгүй. Тухайлбал тодорхой үүрэг, мэргэжил, зан төлөвийг зөвхөн аль нэг хүйст илүү тохирно гэж үзэх хэвшмэл ойлголт нь хувь хүний сонголт, хөгжлийн боломжийг хязгаарлах эрсдэлтэй. Иймээс хүйсийн тэгш байдлыг хангах асуудал нь зөвхөн эрх зүйн зохицуулалт бус, мэдээллийн хүртээмж, боловсрол, нийгмийн ойлголт, харилцааны соёлтой нягт холбоотой.

1.2.2 Нийгмийн хүртээмжтэй байдлын ойлголт

Нийгмийн хүртээмжтэй байдал нь хүн бүр өөрийн гарал үүсэл, хүйс, нас, хөгжлийн бэрхшээл, хэл, соёл, нийгэм-эдийн засгийн нөхцөл байдлаас үл хамааран нийгмийн амьдралд тэгш оролцох, үйлчилгээ авах, шийдвэр гаргалтад дуу хоолойгоо хүргэх боломжтой байх нөхцөлийг илэрхийлдэг [2]. НҮБ-ын Нийгмийн хөгжлийн хөтөлбөрүүдэд нийгмийн оролцоог тэгш хангах, үйлчилгээний тэгш хүртээмжийг дэмжих нь social inclusion-ийн гол зорилго гэж үздэг.

Хүртээмжтэй байдал нь зөвхөн бодит орчны асуудал биш бөгөөд мэдээллийн хүртээмжтэй байдал, ойлгомжтой хэл найруулга, дижитал системд тэгш хандах боломж зэрэгтэй холбоотой. Иймээс нийгмийн хүртээмжтэй орчныг дэмжихэд хэрэглэгч төвтэй, энгийн, ойлгомжтой, ялгаварлан гадуурхахгүй мэдээллийн үйлчилгээ чухал ач холбогдолтой.

1.2.3 Ялгаварлан гадуурхалт, дээрэлхэлт ба нийгмийн ач холбогдол

Хүйсийн болон нийгмийн тэгш бус байдлын нэг илрэл нь ялгаварлан гадуурхалт, гадуурхал, дээрэлхэлт хэлбэрээр илэрдэг. Энэ нь боловсролын орчин, ажлын байр, цахим орчин, нийгмийн өдөр тутмын харилцаанд ажиглагдаж болно. UNESCO-гийн мэдээлснээр дэлхийн хэмжээнд сурагчдын 30 хувиас дээш нь дээрэлхэлтэд өртсөн байдаг бөгөөд энэ нь сурлагын амжилт, сэтгэл зүй, эрүүл мэнд, сургууль завсардалт зэрэгт сөргөөр нөлөөлдөг [3]. Иймээс тэгш харилцаа, харилцан хүндлэл, гадуурхлын эсрэг ойлголтыг зөв түгээх нь зөвхөн онолын бус, бодит нийгмийн ач холбогдолтой асуудал юм.

Нөгөө талаас ажлын байр, байгууллагын орчинд тэгш боломж, ялгаварлан гадуурхалтаас ангид байх асуудал нь хөдөлмөрийн эрх, аюулгүй орчин, шударга үнэлгээ, нийгмийн оролцоотой холбогддог. Ийм мэдээллийг зөв эх сурвалжид тулгуурлан, энгийн ойлгомжтой хэлбэрээр түгээх нь хэрэглэгчийн мэдлэгийг нэмэгдүүлэхээс гадна урьдчилан сэргийлэх ач холбогдолтой.

Дэлхийн хэмжээнд хүйсийн тэгш бус байдал, хүчирхийлэл, гадуурхал хэвээр тулгамдсан хэвээр буйг олон улсын тайлан, статистик мэдээ нотолж байна. Дэлхийн эдийн засгийн чуулганы 2023 оны *Global Gender Gap Report*-д өнөөгийн өсөлтийн хурдаар бүх салбарт бүрэн хүйсийн тэгш байдалд хүрэхэд ойролцоогоор 131 жил шаардагдана гэж тооцоолсон [4]. Дэлхийн Эрүүл Мэндийн Байгууллагын дүн шинжилгээгээр амьдралынхаа явцад бие махбод эсвэл бэлгийн хүчирхийлэлд өртсөн эмэгтэйчүүд дэлхий нийтийн эмэгтэйчүүдийн 27 орчим хувийг эзэлдэг [5], мөн ажиллах хүчний оролцоонд эрэгтэй,

эмэгтэйчүүдийн зөрүү ойролцоогоор 25 нэгж хувь хэвээр байгааг НҮБ-ын Эмэгтэйчүүдийн байгууллага мэдээлдэг [1, 6]. UNESCO-гийн судалгаагаар дэлхийн сурагчдын 30 хувиас дээш нь дээрэлхэлтэд өртөж байна [3].

Монгол Улсын хувьд хүүхдийн эсрэг хүчирхийллийн нөхцөл байдлын талаарх судалгааг UNICEF Mongolia тогтмол явуулж байгаа [7], мөн Үндэсний статистикийн хороо хүйсийн тэгш байдлын үзүүлэлтүүдийг жил бүр нийтэлж байна [8]. Монгол Улсын Хүний эрхийн Үндэсний Комисс жил бүр хүний эрхийн төлөв байдлын талаар албан ёсны илтгэл гаргадаг бөгөөд энэ нь бодлогын болон судалгааны эх сурвалж болдог [9]. Эдгээр үзүүлэлтээс харахад тэгш бус байдал, хүчирхийлэл, гадуурхал нь зөвхөн хувь хүний түвшний асуудал биш, дэлхий нийтийн болон Монгол Улсын хэмжээнд хэвээр буй системчилсэн асуудал юм. Иймээс холбогдох мэдээлэл, эрх зүйн зохицуулалт, тусламжийн сувгуудыг хэрэглэгчдэд хүртээмжтэй хэлбэрээр хүргэх AI шийдэл бий болгох нь нийгмийн хэрэгцээтэй уялдаатай.

1.3 Хиймэл оюун ухаан ба байгалийн хэл боловсруулалт

1.3.1 Хиймэл оюун ухааны үндсэн ойлголт

Хиймэл оюун ухаан нь өгөгдөлд тулгуурлан суралцах, хэв шинж илрүүлэх, таамаг гаргах, асуудал шийдвэрлэх, хүний хэлтэй төстэй мэдээлэл боловсруулах зэрэг чадварыг компьютерийн системд хэрэгжүүлэх технологийн өргөн хүрээний салбар юм. Орчин үеийн AI системүүд нь машин сургалт, гүн сургалт, компьютер хараа, байгалийн хэл боловсруулалт зэрэг олон дэд чиглэлээс бүрддэг.

Нийгмийн чиглэлийн асуудалд AI ашиглах үед зөвхөн техникийн үзүүлэлт бус, өгөгдлийн чанар, тайлбарлах боломж, шударга байдал, хэрэглэгчийн аюулгүй байдал зэрэг хүчин зүйлс давхар чухал болдог. Ялангуяа тэгш байдал, гадуурхал, эмзэг сэдэвтэй холбоотой мэдээллийн системд AI-ийн хариулт зөв, хүндэтгэлтэй, эх сурвалжтай байх шаардлага тавигдана.

1.3.2 Байгалийн хэл боловсруулалт

Байгалийн хэл боловсруулалт (Natural Language Processing, NLP) нь компьютерыг хүний хэлээр бичигдсэн эсвэл илэрхийлэгдсэн мэдээллийг ойлгох, ангилах, боловсруулах, тайлбарлах, хариу үүсгэх боломжтой болгодог салбар юм. NLP-ийн хэрэглээ нь машин орчуулга, асуулт-хариултын систем, текст

ангилал, sentiment analysis, chatbot, virtual assistant зэрэг олон төрлийн системд ашиглагддаг.

Чатботын хувьд NLP нь хэрэглэгчийн асуултын утгыг ойлгох, гол түлхүүр санааг ялгах, асуултын зорилгыг тодорхойлох, тохирсон хариултын бүтэц үүсгэхэд чухал үүрэгтэй. Иймээс NLP нь хиймэл оюун ухаанд суурилсан чатботын технологийн гол үндэс болдог.

1.3.3 Трансформер архитектур ба том хэлний загвар

Орчин үеийн NLP-ийн томоохон ахиц нь трансформер архитектурын хөгжлөөс эхэлсэн гэж үздэг. *Attention Is All You Need* өгүүлэлд танилцуулсан трансформер архитектур нь self-attention механизмаар дамжуулан өгүүлбэр дэх үгсийн хоорондын хамаарлыг илүү үр дүнтэй моделчилж, дараалал боловсруулах чанарыг сайжруулсан [10]. Үүний дараа BERT зэрэг pretrained language model-ууд гарч ирснээр хэлний контекст ойлгох чанар эрс сайжирсан [11]. Sequence-to-sequence хувирлыг нэгтгэсэн T5 хэв шинж [12], цаашлаад GPT-3-аас эхэлсэн few-shot, in-context learning чадвар [13], мөн хүний санал хүсэлтэд тулгуурлан суралцах (RLHF) аргачлал [14] нь өнөөгийн LLM-ийн үндэс суурийг тогтоосон.

Том хэлний загвар (Large Language Model, LLM) нь их хэмжээний текст өгөгдөл дээр урьдчилан сургагдсан, хэрэглэгчийн асуултанд уян хатан, байгалийн хэлбэртэй хариулт үүсгэх чадвартай загвар юм. Гэвч LLM нь дангаараа ажиллах үед тухайн байгууллага, сэдэв, хууль эрх зүйн тусгай мэдлэгийг бүрэн зөв мэдэхгүй байх, мөн эх сурвалжгүй зохиомол мэдээлэл гаргах эрсдэлтэй. Энэ эрсдэлийг судлаачид stochastic parrots зэрэг шүүмжлэлээр тодорхойлсон бөгөөд [15], галлюцинацийн судалгаанууд галлюцинацийг intrinsic (өгөгдсөн контекстээс хазайх) ба extrinsic (баримтгүй шинэ мэдээлэл нэмэх) гэж ангилдаг [16, 17]. Иймээс өндөр нарийвчлал, эх сурвалжийн шаардлагатай орчинд LLM-ийг нэмэлт мэдлэгийн сантай хослуулах шаардлагатай.

Хүснэгт 1.1-д орчин үеийн өргөн ашиглагдаж буй LLM-уудын ерөнхий шинж чанарыг танилцуулав. Үнэлгээний шалгуурт олон хэлт чадвар, контекстийн цонхны хэмжээ, нээлттэй эх эсэх, хэрэглэхэд хялбар интерфэйс зэрэг хүчин зүйлс орно.

Тус судалгаанд Gemini загварыг [18] сонгосон үндэслэлийг 3-р бүлэгт нарийвчлан тайлбарласан болно: гол шалтгаан нь Монгол хэлний дэмжлэг, олон хэлт чадвар, API-р дамжуулан хурдан холбогдох боломж, контекст цонхны хэмжээ юм.

Загвар	Гаргагч	Контекст	Нээлттэй	Онцлог
GPT-3.5 / GPT-4 [13, 14]	OpenAI	8K–128K	Үгүй	RLHF, инструкц дагах өндөр чанартай
Gemini 1.x / 2.x [18]	Google DeepMind	1M хүртэл	Үгүй (API)	Multimodal, маш урт контекст, олон хэлт
Claude 3.x	Anthropic	200K	Үгүй	Constitutional AI, аюулгүй харилцаа
LLaMA 2 / 3	Meta	4K–128K	Тийм (лиценстэй)	Локал орчинд ажиллах боломжтой, open-weight
Mistral / Mixtral	Mistral AI	32K хүртэл	Тийм (зарим нь)	Mixture-of-Experts, бара зардалтай
T5 / Flan-T5 [12]	Google	512–2K	Тийм	Encoder-decoder, fine-tune-д тохиромжтой

Хүснэгт 1.1: Том хэлний загваруудын ерөнхий харьцуулалт

1.4 Чатбот систем ба баримтад тулгуурласан хариулт үүсгэх аргачлал

1.4.1 Чатбот системийн ойлголт ба ангилал

Чатбот нь хэрэглэгчтэй текст эсвэл дуу хоолойгоор харилцаж, мэдээлэл өгөх, асуултад хариулах, зөвлөмж хүргэх зориулалттай програм хангамжийн систем юм. Судалгааны бүтээлүүдэд чатботыг дүрэмд суурилсан, retrieval-д суурилсан, генератив, гибрид хэлбэрээр ангилдаг [19]. Дүрэмд суурилсан чатбот нь урьдчилан тогтоосон нөхцөл, логик, түлхүүр үг дээр ажилладаг бол генератив чатбот нь хэрэглэгчийн асуултын утгыг илүү өргөн хүрээнд ойлгон шинэ хариулт үүсгэх боломжтой.

Хүйсийн болон нийгмийн тэгш байдалтай холбоотой сэдэвт чатбот нь зөвхөн яриа өрнүүлэхээс гадна хэрэглэгчид мэдээлэл өгөх, зөв ойлголт түгээх, эх сурвалж руу чиглүүлэх, зарим тохиолдолд дэмжих өнгө аястай харилцах шаардлагатай байдаг. Иймд ийм төрлийн систем нь зөвхөн generative байхаас гадна баримтад тулгуурлах чадвартай байх нь чухал.

Чатбот системүүдийг үндсэн ангилалаар нь харьцуулсан үзүүлэлтийг Хүснэгт 1.2-д харуулав. Энэхүү харьцуулалт нь зохиомжийн шатанд тохирох төрлийг сонгох үндэс болж өгнө.

Төрөл	Гол ажиллах зарчим	Давуу тал	Сул тал
Дүрэмд суурилсан (rule-based)	Урьдчилан тогтоосон if-then дүрэм, түлхүүр үг, шийдвэрийн мод	Тогтвортой, тайлбарлахад хялбар, эмзэг сэдвийг хатуу хяналтанд авна	Уян хатан биш, NLP-ийн өргөн хүрээний асуултанд хариулж чадахгүй
Retrieval-д суурилсан	Урьдчилан зохиосон хариултын сан, асуултын утгаойролцоо хайлт	Хариулт нийцтэй, баримтаас хазайхгүй, FAQ-д тохиромжтой	Шинэ агуулга үүсгэж чадахгүй, мэдлэгийн сангаас гадуур асуултанд эмзэг
Генератив (LLM-based)	LLM-ээр хариултыг шинээр үүсгэх [10, 13]	Өргөн хүрээний асуултанд уян хатан, хүний хэлбэртэй хариулт	Эх сурвалжгүй, галлюцинацийн эрсдэлтэй [15, 17]
Гибрид (RAG)	Retrieval + Generation: мэдлэгийн сангаас баримтыг татаж, LLM-ээр хариу үүсгэх [20, 21]	Эх сурвалжид тулгуурласан, шинэчлэгдэх боломжтой, ишлэлтэй хариулт	Pipeline нийлмэл; retrieval-ийн чанараас хариулт хамаардаг

Хүснэгт 1.2: Чатбот системийн үндсэн ангилалын харьцуулалт [19]

Энэхүү харьцуулалтаас үзэхэд хүйсийн тэгш байдал, гадуурхлын эсрэг сэдэвт, тогтмол шинэчлэгдэх албан ёсны эх сурвалжид тулгуурлах шаардлагатай орчинд гибрид RAG төрлийн архитектур хамгийн тохиромжтой сонголт болж байна.

1.4.2 Чатбот системийн үндсэн бүтэц

Чатбот систем нь ерөнхийдөө дараах бүрэлдэхүүн хэсгүүдтэй:

- хэрэглэгчийн интерфэйс,
- асуулт боловсруулах модуль,
- мэдлэгийн сан,
- retrieval эсвэл search модуль,
- хариулт үүсгэх загвар,
- хяналт, лог, санал хүсэлтийн модуль.

Эдгээр бүрэлдэхүүн хэсгүүд нь харилцан уялдаатай ажилласнаар хэрэглэгчийн асуултыг хүлээн авч, холбогдох мэдээллийг олж, эцсийн хариултыг ойлгомжтой хэлбэрээр хүргэх боломж бүрддэг. Хэрэв систем нь мэдлэгийн сантай холбогдсон бол тухайн сэдэвт илүү бодитой, эх сурвалжтай хариулт өгөх нөхцөл бүрдэнэ.

1.4.3 Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG) нь хэрэглэгчийн асуултад хариу үүсгэхээс өмнө гаднын мэдлэгийн сангаас холбогдох мэдээллийг хайж татан авч, түүний дараа том хэлний загвараар хариулт үүсгэдэг аргачлал юм [20]. Энэ нь генератив чадвар болон search/retrieval чадварыг нэгтгэдэг учраас ялангуяа баримт, бодлого, заавар, хууль эрх зүйн мэдээлэл дээр суурилсан системд тохиромжтой.

RAG-ийн ерөнхий урсгал нь дараах үе шатуудаас бүрдэнэ:

1. Баримт бичгийг цуглуулах, цэвэрлэх
2. Хэсэглэх (chunking)
3. Embedding үүсгэх
4. Вектор хайлт хийх
5. Хамгийн хамааралтай хэсгүүдийг татах
6. Татсан эх сурвалжид тулгуурлан хариулт үүсгэх

RAG аргачлал нь дараах үндсэн давуу талуудтай:

- **Буруу мэдээлэл үүсэх эрсдэлийг бууруулах:** хариулт нь зөвхөн загварын ерөнхий мэдлэг бус, гаднын мэдлэгийн сангаас татсан баримтад тулгуурлана.
- **Мэдлэгийн санг шинэчлэх боломж:** шинэ баримт бичиг, журам, бодлого нэмэгдэхэд загварыг дахин сургахгүйгээр системийн мэдлэгийг өргөтгөж болно.
- **Эх сурвалжийн ил тод байдал:** хариултад ашигласан баримтын хэсгийг ишлэх, тайлбарлах боломжтой.

RAG-д вектор хайлт чухал үүрэгтэй. Вектор хайлтын системүүд нь асуулт болон баримтын хэсгийг embedding болгон дүрслээд тэдгээрийн утгын ойролцоо байдлыг тооцоолж хайлт хийдэг. ChromaDB зэрэг embedded вектор сангууд нь ийм хайлтыг metadata filter-тэй хослуулан үр ашигтай хийхэд ашиглагддаг [22]. Retrieval болон generation-ийг ийнхүү нэгтгэх нь open-domain question answering болон knowledge-intensive NLP системүүдэд өндөр ач холбогдолтой [21].

1.5 Хариуцлагатай AI ба хүртээмжтэй харилцааны зарчим

1.5.1 Хариуцлагатай AI-ийн үндсэн ойлголт

Хүйсийн болон нийгмийн тэгш байдалтай холбоотой сэдэвт AI систем боловсруулахад зөвхөн техникийн үзүүлэлт хангалтгүй бөгөөд ёс зүй, шударга байдал, тайлбарлах боломж, хэрэглэгчийн аюулгүй байдлыг хамтад нь авч үзэх шаардлагатай. Responsible AI-ийн түгээмэл зарчимд fairness, reliability and safety, privacy and security, inclusiveness, transparency, accountability зэрэг ойлголтууд багтдаг [23]. Эдгээр зарчим нь NIST-ийн AI Risk Management Framework [24] болон Европын Холбооны AI Act-ын [25] ерөнхий чиглэлтэй уялдаатай бөгөөд эмзэг хэрэглээний орчинд AI системийг хариуцлагатай ашиглах үндэс болдог.

Хүснэгт 1.3-д эдгээр үндсэн зарчмуудыг тэдгээрийн тайлбар болон энэхүү дипломын ажлын системд хэрэгжүүлсэн арга замтай харьцуулан танилцуулав.

Зарчим	Тайлбар	Системд хэрэгжүүлэх арга
Fairness (шударга байдал)	Хэрэглэгчийн хүйс, нас, угсаа, хөгжлийн бэрхшээлээс үл хамаарч тэгш үр дүн өгөх	Олон эх сурвалжаас баримт татах, төвийг сахисан prompt хэв шинж тогтоох
Reliability and safety (найдвартай, аюулгүй)	Алдаа, эрсдэлийг урьдчилан хянах, аюулгүй харилцаа	Crisis indicator-аар амь насанд аюултай нөхцлийг таних, тусламжийн утас руу шилжүүлэх
Privacy and security (нууцлал)	Хувийн өгөгдлийг хамгаалах, шаардлагагүй хадгалалтаас зайлсхийх	Локал вектор сан, audit log, API руу зөвхөн контекстийн хэсэг дамжуулах
Inclusiveness (хүртээмжтэй байдал)	Олон хэл, олон төрлийн хэрэглэгчид тэгш хүрэх	Монгол хэл дээрх UI, олон хэлт embedding (bge-m3)
Transparency (ил тод байдал)	AI шийдвэрийн үндэслэлийг тайлбарлах, эх сурвалжийг харуулах	Хариултад retrieved sources-г хавсаргах, model_used талбар лог
Accountability (хариуцлага)	Системийн алдаа, гажуудлын төлөө хариуцагч тал тогтоох	chat_logs-г хадгалах, санал хүсэлтийн механизм, лог хяналт

Хүснэгт 1.3: Хариуцлагатай AI-ийн зарчмууд ба судалгааны системд хэрэгжүүлэх арга [23, 24]

1.5.2 Ялгаварлан гадуурхахгүй харилцаа ба хүртээмжтэй дизайн

Тэгш, хүртээмжтэй байдлыг дэмжих зорилготой чатбот нь хүйс, нас, нийгмийн бүлэг, соёлын ялгаа зэргийг буруу хэвшмэл ойлголтоор илэрхийлэхээс зайлсхийх ёстой. Хэл найруулга нь төвийг сахисан, хүндэтгэлтэй, ойлгомжтой байх нь хэрэглэгчийн итгэлцэлд чухал нөлөөтэй. Мөн хэрэглэгчийг шүүх, буруутгах өнгө аястай бус, мэдээлэл өгөх, чиглүүлэх, ойлголт нэмэгдүүлэх өнгө аястай байх шаардлагатай.

Ийм төрлийн системийн хүртээмжтэй дизайн нь зөвхөн үгийн сонголт бус, хэрэглэгчийн асуултын түвшин, мэдээллийн ойлгомжтой байдал, хариултын бүтэц, эх сурвалж руу шилжих боломж, хэл найруулгын энгийн байдал зэрэгтэй холбоотой. Өөрөөр хэлбэл хүртээмжтэй харилцаа нь интерфэйс, контент, хэл найруулга, алгоритмын хариуцлагыг хамтад нь авч үздэг.

1.6 Хууль эрх зүй ба бодлогын орчин

1.6.1 Монгол Улсын эрх зүйн зохицуулалт

Хүйсийн болон нийгмийн тэгш байдлыг хангах асуудал нь Монгол Улсын хууль эрх зүйн зохицуулалттай холбоотой. Жендэрийн эрх тэгш байдлыг хангах тухай хууль нь хүйсээр ялгаварлан гадуурхахыг хориглох, бодлого, хөтөлбөр, арга хэмжээнд жендэрийн мэдрэмжтэй хандах үндэс суурийг тогтоодог [26]. Мөн Хөдөлмөрийн тухай хууль нь хөдөлмөр эрхлэлт, ажлын байрны харилцаанд ялгаварлан гадуурхалтаас ангид байх зарчмыг агуулдаг [27].

Эдгээр хууль эрх зүйн зохицуулалт нь AI чатботын мэдлэгийн санд ашиглах боломжтой баталгаатай эх сурвалж болж өгнө. Ялангуяа хэрэглэгч эрх, үүрэг, ялгаварлан гадуурхалтын талаарх асуулт асуух үед албан ёсны мэдээлэлд тулгуурлан хариулах шаардлагатай.

1.6.2 Олон улсын зарчим ба стандарт

Олон улсын түвшинд ялгаварлан гадуурхалтаас ангид байх, тэгш боломжийг хангахтай холбоотой үндсэн баримт бичгүүд бий. Тухайлбал Олон улсын хөдөлмөрийн байгууллагын 111 дүгээр конвенц нь ажил эрхлэлт, мэргэжлийн орчин дахь ялгаварлан гадуурхалтын эсрэг үндсэн зарчмыг тодорхойлдог [28]. Ийм олон улсын баримт бичгүүд нь тэгш байдал, хүртээмжийн тухай ойлголтыг нийгмийн болон байгууллагын түвшинд авч үзэхэд чухал лавлагаа болдог.

1.7 Бүлгийн дүгнэлт

Энэхүү бүлэгт хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлын тухай суурь ойлголт, ялгаварлан гадуурхалт ба гадуурхлын нийгмийн ач холбогдол, хиймэл оюун ухаан болон байгалийн хэл боловсруулалтын үндэс, чатбот системийн бүтэц, Retrieval-Augmented Generation аргачлалын үүрэг, мөн хариуцлагатай AI-ийн зарчмуудыг авч үзлээ. Эдгээр онолын үндэс нь хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлыг хангахад чиглэсэн хиймэл оюун ухаант чатбот системийн архитектур, мэдлэгийн сан, харилцааны зарчмыг тодорхойлоход суурь болох юм.

БҮЛЭГ 2

Судалгаа ба шийдлийн загвар

2.1 Бүлгийн зорилго

Энэхүү бүлэгт хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлыг хангахад чиглэсэн хиймэл оюун ухаант чатбот системийн судалгаа, шийдлийн загвар, технологийн сонголт, мэдлэгийн сан бүрдүүлэх арга зүй, хамгаалалтын зарчим болон үнэлгээний аргачлалыг тодорхойлно. Мөн ижил төстэй системүүдийг харьцуулан судалж, энэхүү дипломын ажилд RAG суурьтай архитектур сонгосон үндэслэлийг тайлбарлана.

2.2 Ижил төстэй системүүдийн судалгаа ба харьцуулалт

Ижил төстэй системүүдийг судлах нь дараах ач холбогдолтой:

- бодит хэрэглээнд ашиглагдаж буй чатбот шийдлүүдийн чиг хандлагыг тодорхойлох,
- тэдгээрийн давуу болон сул талыг харьцуулах,
- өөрийн системийн шаардлага, архитектурын сонголтыг үндэслэх.

Сүүлийн жилүүдэд байгууллагын үйлчилгээ, бодлого журам тайлбарлах систем, төрийн үйлчилгээний мэдээллийн системүүдэд чатбот технологи өргөн ашиглагдах болсон. Тухайлбал байгууллагын хүний нөөцийн үйлчилгээнд виртуал агент ашиглах, байгууллагын мэдлэгийн сан дээр суурилсан генератив агент хөгжүүлэх, олон нийтэд зориулсан бодлого тайлбарлах чат систем турших зэрэг жишээнүүд бий [29, 30, 31].

2.2.1 Харьцуулалтын шалгуур

Ижил төстэй системүүдийг дараах шалгуураар харьцуулсан болно:

- **Домэйн ба хэрэглэгч:** байгууллагын дотоод хэрэглээ, олон нийтэд зориулсан үйлчилгээ, эсвэл хосолсон хэрэглээ.
- **Мэдлэгийн эх сурвалж:** бодлого, журам, гарын авлага, хууль эрх зүйн эх сурвалж, FAQ зэрэгт суурилдаг эсэх.
- **Хариултын механизм:** дүрэмд суурилсан, retrieval-д суурилсан, эсвэл RAG/LLM ашигладаг эсэх.
- **Эх сурвалжийн ил тод байдал:** хариултад ашигласан эх сурвалжийг харуулах боломж.
- **Аюулгүй байдал:** эмзэг агуулгатай сэдэвт хязгаарлалт, чиглүүлэлт, хүний оролцоотой шийдэлтэй эсэх.

- **Өргөтгөх боломж:** шинэ баримт бичиг, шинэ домэйн, шинэ платформтой холбох боломж.

2.2.2 Харьцуулалтын хүснэгт

Хүснэгт 2.1-д ижил төстэй системүүдийн харьцуулалтыг өргөтгөсөн хувилбараар үзүүлэв. Сонгосон системүүд нь олон улсын болон Монгол Улсын хэмжээнд бодит хэрэглээтэй, RAG/LLM-д суурилсан эсвэл retrieval/rule-based загвартай чатбот шийдлүүд юм.

2.2.3 Судалгааны дүгнэлт

Дээрх жишээнүүдээс харахад чатбот системүүд нь хэрэглэгчийн асуултад шуурхай, ойлгомжтой хариулах давуу талтай боловч бодлого, эрх зүй, тэгш байдал зэрэг эмзэг сэдэвтэй орчинд зөв эх сурвалжид тулгуурлах шаардлага өндөр байна. Ялангуяа хүйсийн тэгш байдал, гадуурхал, дээрэлхэлт, нийгмийн оролцооны талаарх асуултад баримтад тулгуурласан, ил тод, тайлбарлах боломжтой хариулт өгөх нь чухал тул энэхүү дипломын ажилд RAG суурьтай архитектур сонгосон.

2.3 Системийн хамрах хүрээ

Энэхүү чатбот системийн агуулгын хамрах хүрээнд хүйс, нас, хөгжлийн бэрхшээл, үндэс угсаа, хэл, төрсөн газар, нийгмийн гарал, эдийн засгийн байдал, бэлгийн чиг баримжаа, хүйсийн баримжаа зэрэг хүчин зүйлээс шалтгаалсан ялгаварлан гадуурхалт, гадуурхал, дээрэлхэлт, тэгш бус хандлагатай холбоотой мэдээллийг хамруулна. Мөн өсвөр үеийн орчин дахь bullying, боловсролын орчин дахь гадуурхал, ажлын байрны тэгш бус хандлага, байгууллагын дотоод харилцааны шударга байдал, хүртээмжтэй орчин бүрдүүлэхтэй холбоотой тайлбар, зөвлөмж, эх сурвалжийг хамруулна.

Системийн зорилтот хэрэглэгч нь өсвөр насны хэрэглэгч, оюутан залуус, ажилтан, ажил олгогч, байгууллагын хүний нөөцийн ажилтан болон эрх тэгш байдал, хүртээмжтэй орчны талаар мэдээлэл авах хүсэлтэй ерөнхий хэрэглэгчид байна. Энэ хүрээнд систем нь зөвлөгөө өгөхөөс илүүтэйгээр ойлголт тайлбарлах, эх сурвалжтай мэдээлэл хүргэх, хэрэглэгчийг зөв чиглэлд чиглүүлэх үүрэгтэй байна.

Систем	Домэйн	Архитектура	Эх сурвалж	Хүчтэй ба сул талууд
ServiceNow HR Virtual Agent [29]	Байгууллагын HR	Rule-based + retrieval	Хязгаарлагдмал	(+) HR процесст оруулсан, олон хэлт. (–) Үнэтэй лиценс, gender домэйнд тусгай мэдлэггүй
Microsoft Copilot Studio + RAG [30]	Байгууллагын мэдлэгийн сан	RAG (Azure AI)	Тийм, citation-той	(+) Grounding өндөр чанартай, ишлэл харуулдаг. (–) Azure-д хамаарал, Монгол хэл хязгаарлагдмал
UK.gov chatbot guidance [31]	Олон нийт төрийн үйлчилгээ	Hybrid	Бичигдсэн	(+) Хэрэглэгч төвтэй UX зөвлөмж. (–) Тусгай чатбот биш, зөвхөн зарчим
ChatGPT (web) [13, 14]	Универсал	Pure LLM	Үгүй (анхдагч)	(+) Уян хатан, олон хэлт. (–) Эх сурвалж заадаггүй, галлюцинацийн эрсдэлтэй
UN Women Q&A портал [1]	Хүйсийн тэгш байдал	Static FAQ	Холбоос	(+) Албан ёсны эх сурвалж. (–) Чатбот биш, харилцан үйлчлэл сул
UNESCO bullying платформ [3]	Сургууль, насанд хүрэгчид	Static content	Тайлан, статистик	(+) Шинжлэх ухаанд тулгуурласан агуулга. (–) Динамик асуулт-хариулт байхгүй
ILO HELPDESK [28]	Хөдөлмөрийн эрх	Retrieval-based	Тийм (конвенцид)	(+) Хууль зүйн чанартай эх сурвалж. (–) UI урт, олон нийтэд хүртээмж сул
Энэхүү ажил (Boloroo)	Хүйс, тэгш байдал, дарамт (Монгол)	RAG (Gemini + ChromaDB)	Тийм, мета өгөгдөлтэй	(+) Монгол хэл, Монголын хууль ба статистикт суурилсан, ишлэлтэй, crisis-routing-той

Хүснэгт 2.1: Ижил төстэй системүүдийн өргөтгөсөн харьцуулалт

2.4 Системийн ерөнхий архитектур

Энэхүү дипломын ажлын хүрээнд хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлын талаарх мэдээллийг хүргэхэд зориулсан RAG (Retrieval-Augmented Generation) суурьтай чатбот системийн архитектурыг боловсруулсан. Систем нь дараах үндсэн бүрэлдэхүүн хэсгүүдээс бүрдэнэ:

- хэрэглэгчийн чат интерфэйс,
- мэдлэгийн сан,
- текст боловсруулах ба embedding үүсгэх модуль,
- вектор хайлт ба retrieval модуль,
- том хэлний загвар (LLM),
- хариултын хяналт, лог болон санал хүсэлтийн бүртгэл.

Системийн ажиллагааны ерөнхий урсгал нь дараах байдалтай. Нэгдүгээрт, хэрэглэгч чат интерфэйсээр асуултаа оруулна. Хоёрдугаарт, систем асуултыг embedding болгон хөрвүүлж, мэдлэгийн сан дахь холбогдох баримтын хэсгүүдтэй утгын ойролцоо байдлаар харьцуулна. Гуравдугаарт, хамгийн хамааралтай баримтын хэсгүүдийг retrieval аргаар татан авч, тэдгээрийг том хэлний загварт контекст болгон өгнө. Дөрөвдүгээрт, том хэлний загвар нь эдгээр эх сурвалжид тулгуурлан хариулт үүсгэнэ. Тавдугаарт, хариултын эх сурвалж болон хэрэглэгчийн санал хүсэлтийг бүртгэж, системийн сайжруулалтад ашиглана.

Ийм архитектур нь зөвхөн том хэлний загварт тулгуурласан системтэй харьцуулахад баримтад тулгуурласан, илүү найдвартай, тайлбарлах боломжтой хариулт үүсгэх давуу талтай.

2.5 Системийн үндсэн функцууд

Систем нь дараах үндсэн функцуудтай байна:

1. Хэрэглэгчийн асуултыг хүлээн авч, текстэн хэлбэрээр хариулт өгөх чат интерфэйс.
2. Мэдлэгийн сангаас асуулттай холбоотой эх сурвалжийн хэсгийг retrieval аргаар хайж татах.
3. Татсан эх сурвалжид тулгуурлан ойлгомжтой, төвийг сахисан хариулт үүсгэх.
4. Хариултад ашигласан эх сурвалжийн хэсгийг харуулах.
5. Эмзэг агуулгатай асуултыг таньж, болгоомжтой, чиглүүлэлттэй хариулах.

6. Хэрэглэгчийн санал хүсэлт, үнэлгээг бүртгэх.
7. Системийн чат, retrieval, гүйцэтгэлийн логийг хадгалж дараагийн сайжруулалтад ашиглах.

2.6 Системийн шаардлагын тодорхойлолт

Энэхүү хэсэгт системийн функциональ болон функциональ бус шаардлагыг тодорхойлно. Эдгээр шаардлага нь 3-р бүлэг дэх хэрэгжилтийн хүрээг тодорхойлж, туршилт үнэлгээнд хэмжигдэхүйц шалгуур болно.

2.6.1 Функциональ шаардлага

1. Хэрэглэгчийн асуултыг хүлээн авч, текстэн хэлбэрээр хариулт өгөх чат интерфэйстэй байх.
2. Хэрэглэгчийн асуулттай холбоотой баримтын хэсгийг мэдлэгийн сангаас хайж татах боломжтой байх.
3. Татан авсан эх сурвалж дээр үндэслэн хариулт үүсгэх боломжтой байх.
4. Хариултад ашигласан эх сурвалжийн хэсгийг харуулах боломжтой байх.
5. Хэрэглэгчийн санал хүсэлт, үнэлгээг бүртгэх боломжтой байх.
6. Системийн хэрэглээний лог, нийтлэг асуулт, сайжруулалтын мэдээллийг өгөгдлийн санд бүртгэх боломжтой байх.
7. Эмзэг агуулгатай асуултад хязгаарлалттай, болгоомжтой, чиглүүлэлттэй хариулах боломжтой байх.

2.6.2 Функциональ бус шаардлага

- **Найдвартай байдал:** баримтад нийцсэн, ойлгомжтой хариулт өгөх.
- **Гүйцэтгэл:** асуултад боломжийн хугацаанд хариулах.
- **Нууцлал ба аюулгүй байдал:** хэрэглэгчийн мэдээллийг зохих түвшинд хамгаалах.
- **Хүртээмжтэй байдал:** ялгаварлан гадуурхахгүй, төвийг сахисан, хэрэглэгчид ээлтэй найруулга ашиглах.
- **Өргөтгөх боломж:** шинэ сэдэв, шинэ эх сурвалж, шинэ орчинд мэдлэгийн санг өргөтгөх боломжтой байх.

2.7 Мэдлэгийн сан бүрдүүлэх судалгаа

RAG системийн хамгийн чухал бүрэлдэхүүн бол мэдлэгийн сан юм. Энэхүү дипломын ажлын хүрээнд мэдлэгийн сан нь хүйсийн болон нийгмийн тэгш

байдал, хүртээмжтэй байдлын талаарх төрөл бүрийн эх сурвалжаас бүрдэнэ. Үүнд:

- тэгш байдал, ялгаварлан гадуурхалтаас сэргийлэх тухай байгууллагын дотоод бодлого,
- өсвөр үе, боловсролын орчин дахь дээрэлхэлт, гадуурхлын талаарх мэдээллийн материал,
- Монгол Улсын хууль эрх зүйн эх сурвалж,
- олон улсын байгууллагын зөвлөмж, конвенц,
- тайлбар, FAQ, гарын авлага зэрэг хэрэглэгч төвтэй контент

орно.

2.7.1 Эх сурвалжийн төрөл

- **Албан ёсны хууль эрх зүйн эх сурвалж:** Хөдөлмөрийн тухай хууль, Жендэрийн эрх тэгш байдлыг хангах тухай хууль [26, 27]
- **Олон улсын стандарт, зөвлөмж:** ILO Convention No.111 болон тэгш боломж, гадуурхлын эсрэг зарчмууд [28]
- **Нийгмийн боловсролын эх сурвалж:** bullying, inclusion, social participation зэрэг сэдвийн тайлбар материал [1, 2, 3]
- **Байгууллагын бодлого ба тайлбар контент:** code of conduct, anti-harassment policy, FAQ, guideline

2.7.2 Баримт боловсруулах үе шат

Мэдлэгийн санд оруулах баримт бичгүүдийг дараах үе шатаар боловсруулна:

1. **Цэвэрлэгээ:** илүүдэл тэмдэгт, header/footer, давхардсан мөрийг арилгах
2. **Структурчлал:** гарчиг, дэд гарчиг, заалт, тайлбар хэсгийг ялгах
3. **Хэсэглэл (chunking):** утгын хувьд холбоотой хэсгүүд болгон хуваах
4. **Мета өгөгдөл хавсаргах:** эх сурвалжийн төрөл, огноо, сэдэв, гарчиг зэргийг тэмдэглэх

2.8 RAG архитектурын сонголт ба параметрийн судалгаа

RAG аргачлалыг сонгох шалтгаан нь энэ системийн хариулт зөвхөн генератив биш, заавал эх сурвалжтай, тайлбарлах боломжтой байх шаардлагатайтай холбоотой. Lewis нарын судалгаанд retrieval-augmented generation нь

knowledge-intensive NLP даалгаварт параметрик-only загвараас илүү үр дүнтэй болохыг харуулсан [20].

RAG архитектур нь хоёр үндсэн үе шаттай:

1. **Retrieval:** хэрэглэгчийн асуулттай утгын хувьд төстэй баримтын хэсгүүдийг мэдлэгийн сангаас хайж олох
2. **Generation:** татсан эх сурвалжийг контекст болгон ашиглаж хариулт үүсгэх

2.8.1 Хэсэглэлтийн стратеги

Хэсэглэлтийн хэмжээ retrieval-ийн чанарт шууд нөлөөлдөг. Хэт жижиг chunk нь утгын холбоосыг алдагдуулж болох бол хэт том chunk нь илүүдэл контент агуулж, хамааралгүй мэдээлэл нэмэх эрсдэлтэй. Иймээс chunk size болон overlap параметруудийг туршилтаар тодорхойлно. Хүснэгт 2.2-д түгээмэл хэрэглэгддэг хэсэглэлтийн стратеги, тэдгээрийн давуу, сул тал, тохиромжтой хэрэглээний орчныг харьцуулсан.

Стратеги	Зарчим	Давуу / сул тал
Тогтмол урт (fixed-size)	Текстийг тогтмол тэмдэгт/токенаар хуваах (жишээ нь 500 тэмдэгт + 50 давхцал)	(+) Энгийн, тэнцвэртэй блок үүсгэнэ. (−) Утгын зааг алдаг
Recursive (header-aware)	Эхлээд догол мөр, дараа нь өгүүлбэр, эцэст нь үг гэх мэтээр түвшин түвшнээр хуваах	(+) Утгын бүтцийг хадгална. (−) Параметр оновчлоход хугацаа их
Sentence-window	Өгүүлбэр бүрийг хэсэг болгож, тойрсон хэдэн өгүүлбэрийг контекстээр оруулах	(+) Нарийн утга барих. (−) Олон жижиг chunk, индекс томрох
Семантик (semantic)	Embedding-ийн утгын тасалдал илэрсэн цэгээр хуваах	(+) Хамгийн чанартай зааг. (−) Тооцоо хийх зардал өндөр
Document-aware	Document-ийн структур (PDF outline, markdown header) ашиглан хуваах	(+) Албан ёсны баримтад тохиромжтой. (−) Source-аас хамаарал өндөр

Хүснэгт 2.2: Хэсэглэлтийн (chunking) стратегийн харьцуулалт

Энэхүү дипломын ажилд эхний хувилбарт fixed-size + overlap стратегийг сонгосон бөгөөд цаашид recursive ба document-aware хэлбэрлүү шилжих боломжтойгоор pipeline-ийг зохион байгуулсан.

2.8.2 Embedding ба вектор хайлт

Embedding нь текстийн утгыг тоон вектор болгон дүрслэх арга бөгөөд retrieval шатны гол үндэс болдог [32, 33]. Вектор хайлтын үед хэрэглэгчийн асуултын embedding болон баримтын хэсгүүдийн embedding-үүдийн ойролцоо байдлыг тооцоолж хамгийн хамааралтай хэсгийг сонгоно. ChromaDB [22] зэрэг тусгайлан вектор сангууд нь metadata filter, persistent storage, олон collection-ийг шууд дэмждэг бөгөөд RAG системд түгээмэл ашиглагддаг.

Embedding загвар сонгох нь олон хэлт орчинд ялангуяа чухал. Хүснэгт 2.3-д өнөөгийн нийтлэг ашиглагдаж буй embedding загваруудын харьцуулалтыг үзүүлэв.

Загвар	Хэмжээ	Контекст	Олон хэлт	Тэмдэглэл
all-MiniLM-L6-v2 [32]	384	512	Хязгаар.	Хурдан, хөнгөн, English-чиглэсэн
multilingual-MiniLM-L12-v2 [32]	384	512	50+ хэл	Олон хэлт энгийн baseline
multilingual-E5-large	1024	512	100 хэл	Asymmetric retrieval-д тохиромжтой
BAAI/bge-m3 [34]	1024	8192	100+ хэл	Dense + sparse + multi-vector хосолсон, Монгол хэлэнд өндөр чанартай
OpenAI text-embedding-3-large	3072	8191	Олон хэлт	API үнэтэй, локалд ажилладаггүй
bge-reranker-v2-m3 [35]	скал. оноо	8192	100+ хэл	Cross-encoder; re-ranking шатанд ашиглагдана

Хүснэгт 2.3: Embedding загваруудын харьцуулалт

Энэхүү судалгаанд BAAI/bge-m3 загварыг сонгосон гол шалтгаан нь Монгол Cyrillic-ийг агуулсан 100 гаруй хэлийг дэмждэг, dense ба sparse retrieval-ийг хослуулсан, 8192 token-ийн урт контекст дэмждэг, нээлттэй эх зөвшөөрөлтэйг харгалзан үзсэн юм.

2.8.3 Top- k ба дахин эрэмбэлэлт

Retrieval шатанд top- k гэдэг нь хамгийн өндөр хамааралтай хэдэн баримтын хэсгийг сонгохыг илэрхийлнэ. Хэрэв k хэт бага байвал чухал эх сурвалж алдагдаж болзошгүй, харин хэт их байвал prompt-д илүүдэл мэдээлэл орж хариултын чанарт сөргөөр нөлөөлж болзошгүй. Иймээс top- k -ийн оновчтой утгыг туршилтаар тогтооно. Шаардлагатай тохиолдолд reranking ашиглан илүү хамааралтай эх сурвалжийг урьтал болгоно.

2.8.4 Prompt загвар ба эх сурвалжийн ишлэл

Хариулт үүсгэх prompt нь дараах зарчмыг баримтална:

- асуултын зорилгыг тодорхойлох,
- retrieval-ээр татсан эх сурвалжийг контекст болгон оруулах,
- баримтаас хазайхгүй байх дүрэм тогтоох,
- боломжтой тохиолдолд эх сурвалжийн үндэслэл харуулах.

Ингэснээр grounded generation буюу эх сурвалжид суурилсан хариулт үүсгэх боломж нэмэгдэнэ [21].

2.9 Хариуцлагатай AI ба хамгаалалтын зохицуулалт

Тэгш байдал, гадуурхал, bullying, нийгмийн оролцоо зэрэг нь эмзэг агуулга бүхий сэдвүүд тул чатбот систем нь болгоомжтой, хариуцлагатай хариулах шаардлагатай. Иймээс дараах хамгаалалтын зарчмуудыг тусгана:

1. **Ялгаварлан гадуурхахгүй найруулга:** хэвшмэл ойлголт давтахгүй, төвийг сахисан, хүндэтгэлтэй хэл ашиглах
2. **Хэт эрсдэлтэй зөвлөгөөнөөс татгалзах:** хууль зүйн эцсийн дүгнэлт, эмчилгээний заавар зэрэг өндөр эрсдэлтэй зөвлөгөөг шууд өгөхгүй байх
3. **Чиглүүлэлт өгөх:** хэрэглэгчийг холбогдох эх сурвалж, албан ёсны байгууллага, үйлчилгээ, бодлогын баримт бичиг рүү чиглүүлэх
4. **Лог ба аудит:** системийн хариулт, retrieval, хэрэглэгчийн үнэлгээ зэргийг бүртгэн сайжруулалтын үндэс болгох

Responsible AI-ийн fairness, transparency, accountability, inclusiveness зэрэг зарчим нь ийм төрлийн системийн үндсэн шаардлага гэж үздэг [23].

2.10 Туршилт ба үнэлгээний аргачлал

Энэхүү системийн үнэлгээг гурван үндсэн чиглэлээр хийнэ: retrieval чанар, хариултын чанар, хэрэглэгчийн үнэлгээ. Хүснэгт 2.4-д ашиглах гол үнэлгээний хэмжүүрүүдийг танилцуулав.

Шат	Хэмжүүр	Тайлбар
Retrieval	Precision@ k , Recall@ k [33]	Top- k дотор хэдэн зөв баримт орсон, хэдэн зөв баримт алдагдсаныг тооцно
Retrieval	Mean Reciprocal Rank (MRR)	Зөв баримтын дундаж урвуу эрэмбийг тооцох; эрэмбэлэлтийн чанарыг хэмжинэ
Retrieval	nDCG@ k	Эрэмбэлэгдсэн үр дүнг ranking-аар нь жигнэсэн чанарын үзүүлэлт
Generation	Faithfulness [36]	Хариулт татсан контекстээс хазайсан эсэх (RAGAS)
Generation	Answer Relevancy [36]	Хариулт асуулттай шууд холбогдсон эсэх
Generation	Context Precision / Recall [36]	Татсан контекст хариултанд хэр хэрэгцээтэй байсныг хэмжих
Generation	Hallucination rate [16, 17]	Эх сурвалжид байхгүй зохиомол мэдээллийн эзлэх хувь
User	Likert (1–5) үнэлгээ	Хэрэглэгчээс ойлгомжтой, итгэл төрсөн, хэрэгтэй эсэх асуултаар цуглуулна
User	Task Success Rate	Хэрэглэгч асуултынхаа хариулт авч чадсан эсэхийг тооцох
System	Latency (ms)	Асуултын хариулт буцах хүртэлх дундаж хугацаа
System	Token usage	LLM-ийн нэг хариулт үүсгэхэд зарцуулсан токен (зардлын үзүүлэлт)

Хүснэгт 2.4: RAG системийн үнэлгээний хэмжүүрүүд

2.10.1 Retrieval чанарын үнэлгээ

Retrieval шатанд зөв эх сурвалж top- k дотор орж ирж байгаа эсэхийг Precision@ k , Recall@ k , MRR ба nDCG зэрэг сонгодог IR хэмжүүрээр хэмжинэ [33]. Туршилтын асуултын багц нь хүйсийн тэгш байдал, дарамт, дээрэлхэлт, гадурхалт, тусламжийн утас зэрэг сэдэв тус бүрд 10–15 асуулт агуулсан байх шаардлагатай. Хэсэглэлтийн хэмжээ, embedding загвар, top- k зэрэг параметрийн нөлөөг харьцуулж үнэлснээр оновчтой тохиргоог тогтооно.

2.10.2 Хариултын чанарын үнэлгээ

Хариултын чанарыг дараах шалгуураар үнэлнэ:

- **Нийцтэй байдал (Relevance):** хариулт асуулттай шууд холбоотой эсэх [36]
- **Ойлгомжтой байдал (Clarity):** хэрэглэгч ойлгоход хялбар эсэх
- **Эх сурвалжтай нийцэл (Faithfulness):** хариулт татсан баримтаас хазайсан эсэх [17, 36]
- **Хэл найруулгын зохистой байдал:** ялгаварлан гадуурхахгүй, төвийг сахисан байдал

Эдгээр шалгуурыг хэмжихэд RAGAS framework [36]-ийг ашиглах боломжтой бөгөөд тус нь LLM-ийг үнэлгээний хэрэгсэл болгон ашиглан faithfulness, answer relevancy, context precision/recall зэрэг автомат хэмжүүрүүдийг тооцдог. Хүний эксперт үнэлгээтэй хослуулснаар үнэлгээний бодит чанарыг хангах боломжтой.

2.10.3 Хэрэглэгчийн үнэлгээ

Хэрэглэгчээс 1–5 онооны үнэлгээ, мөн чанарын санал хүсэлт цуглуулна. Үүнд:

- мэдээлэл ойлгомжтой байсан эсэх,
- хариулт хэрэгтэй байсан эсэх,
- эх сурвалжтай байдал итгэл төрүүлсэн эсэх

зэрэг шалгуур орно.

2.11 Бүлгийн дүгнэлт

Энэхүү бүлэгт ижил төстэй системүүдийн судалгаа, санал болгож буй системийн ерөнхий архитектур, системийн хамрах хүрээ, үндсэн функцууд, мэдлэгийн сан бүрдүүлэх арга зүй, RAG архитектурын сонголт, хэсэглэлтийн стратеги, embedding загваруудын харьцуулалт, хариуцлагатай AI-ийн хамгаалалтын зарчим болон үнэлгээний аргачлалыг тодорхойллоо. Судалгаанаас үзэхэд хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлын талаарх чат-бот систем нь заавал баримтад тулгуурласан, тайлбарлах боломжтой, ялгаварлан гадуурхахгүй байх шаардлагатай байна. Embedding загвар, хэсэглэлтийн стратеги, retrieval ба generation хоёр шатны үнэлгээний хэмжүүрүүдийг тодорхой болгосон нь дараагийн бүлэгт системийг хэрэгжүүлэх, туршихад баримтлах үндэс суурь болж байна. Иймээс энэхүү дипломын ажилд RAG

суурьтай (BAAI/bge-m3 embedding + ChromaDB + Gemini), эх сурвалжийн ил тод байдал бүхий чатбот архитектурыг сонгож, дараагийн бүлэгт түүний хэрэгжилтийг авч үзнэ.

БҮЛЭГ 3

Системийн зохиомж, диаграм

Энэ бүлэгт хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлыг хангахад чиглэсэн хиймэл оюунт чатбот зохиомжийг тодорхойлов. Системийн архитектур, үндсэн класс бүтэц, хэрэглэгчийн асуултад хариулах дараалал, баримт бичиг оруулах болон боловсруулах урсгал, байршуулалтын орчин, өгөгдлийн сангийн бүтэц, мөн аюулгүй байдал ба нууцлалын зохиомжийг тус тус авч үзсэн болно. Зохиомжийн үндэс нь Retrieval-Augmented Generation (RAG) аргачлал [20] бөгөөд хариултыг мэдлэгийн санд тулгуурлуулан үүсгэх замаар хэлний загварын галлюцинацийн эрсдэлийг бууруулах зорилготой [16, 17].


3.1 Системийн ерөнхий архитектур

Зураг 3.1-д системийн ерөнхий архитектурыг харуулав. Хэрэглэгч веб интерфэйсээр дамжуулан асуултаа илгээх бөгөөд backend API нь хүсэлтийг **ChatService** хэсэг рүү дамжуулна. **ChatService** нь RAG pipeline-ыг ашиглан хэрэглэгчийн асуулттай хамааралтай баримт бичгийн хэсгүүдийг ChromaDB вектор сангаас [22] хайж, олдсон контекст мэдээллийг Google Gemini хэлний загварт [18, 37] дамжуулан эцсийн хариултыг үүсгэнэ.

Мэдлэгийн санд оруулах баримтуудыг урьдчилан, ажиллах орчноос гадуур (offline) дамжуулдаг бөгөөд `scripts/ingest.py` CLI хэрэгсэл нь баримт ачаалах, текст задлах, хэсэгчлэх, embedding үүсгэх, вектор санд хадгалах, мета өгөгдлийг өгөгдлийн санд бүртгэх үүрэгтэй. Embedding үүсгэх шатанд BAAI/bge-m3 олон хэлний шигтгээний загвар [34], дахин эрэмбэлэлтэд BAAI/bge-reranker-v2-m3 загвар [35] ашиглагдана. Ийнхүү ажиллах үед чатбот нь зөвхөн уншиж ажиллах горимтой бөгөөд хэрэглэгчийн асуултад зөвхөн ерөнхий хэлний загварын мэдлэгээр бус, эх сурвалжид тулгуурлан хариулт өгөх боломжтой болно.

3.2 Архитектурын сонголтын үндэслэл

Энэхүү системд RAG архитектурыг сонгосон гол шалтгаан нь байнга шинэчлэгдэх боломжтой баримт бичигт суурилсан хариулт өгөх шаардлагатай байсантай холбоотой [20, 21]. Зөвхөн ерөнхий хэлний загварт тулгуурласан чатбот нь нарийвчилсан мэдээллийг шууд мэдэх боломжгүй бөгөөд эх сурвалжгүй зохиомол мэдээлэл үүсгэх эрсдэлтэй [15, 17]. Харин RAG архитектур нь баримт бичгийг урьдчилан боловсруулж мэдлэгийн санд хадгалан, хэрэглэгчийн асуулттай хамгийн их хамааралтай хэсгийг хайж олдог тул илүү эх сурвалжид тулгуурласан хариулт үүсгэх давуу талтай.



ЗУРАГ 3.1: Системийн ерөнхий архитектур

Frontend хэсэгт React [38] болон Vite [39]-ийг ашигласнаар хэрэглэгчийн интерфэйсийг уян хатан хөгжүүлэх боломж бүрдэнэ. Backend хэсэгт FastAPI [40]-ийг ашигласнаар API endpoint-уудыг асинхрон ажиллагаатай, өндөр гүйцэтгэлтэйгээр боловсруулах, Pydantic-д суурилсан өгөгдлийн шалгалт хийх, frontend болон AI pipeline хоорондын харилцааг зохион байгуулах боломжтой. Семантик хайлтын үе шатанд ChromaDB вектор санг [22] ашигласан бөгөөд энэ нь Python-д интеграц хийхэд хялбар, дискэнд тогтвортой хадгалагдах (persistent), мета өгөгдлийн шүүлтүүртэй хайлт дэмждэг давуу талтай. Шигтгээ үүсгэхэд олон хэлний BAAI/bge-m3 [34] загвар, дахин эрэмбэлэлтэд BAAI/bge-reranker-v2-m3 [35] загварыг ашиглаж байгаа нь Монгол хэл болон бусад хэлэн дээрх хайлтын чанарт ач холбогдолтой. Хариулт үүсгэх хэсэгт Google-ийн Gemini 2.5 Flash хэлний загварыг [18, 37] REST API-р дамжуулан холбосон бөгөөд энэ нь олон хэл дэмждэг, контекстийн өргөн цонхтой, гүйцэтгэлийн зардал ба чанарын тэнцвэртэй сонголт юм. Реляц өгөгдлийн санд SQLite [41]-ийг ашигласан нь dependency багатай, бие даасан туршилтын орчинд тохиромжтой шийдэл болсон.

Архитектурын үндсэн давуу тал нь хэрэглэгчийн интерфэйс, backend API, баримт бичиг боловсруулах хэсэг, вектор хайлт болон хариулт үүсгэх хэсгүүдийг тус тусад нь салгасан явдал юм. Энэ нь системийг цаашид өргөтгөх, шинэ өгөгдөл нэмэх, хэрэглэгчийн интерфэйсийг өөрчлөх, эсвэл хэлний загварыг солих үед бүх системийг дахин бичихгүйгээр хэсэгчлэн сайжруулах боломжийг бүрдүүлнэ.

3.2.1 Технологийн стек ба сонголтын үндэслэл

Системд ашиглаж буй технологийн стекийг Хүснэгт 3.1-д нэгтгэн харуулав. Сонголт бүр нь нээлттэй эх, олон нийтийн дэмжлэгтэй, дипломын ажлын туршилтын хэмжээнд тохиромжтой, цаашид үйлдвэрлэлийн орчинд өргөтгөх боломжтой байх шалгуурыг хангадаг.

3.3 Өгөгдлийн сангийн бүтэц

Систем нь баримт бичгийн мета өгөгдөл, боловсруулсан текстийн хэсгүүд болон хэрэглэгчийн харилцан үйлчлэлтэй холбоотой мэдээллийг хадгалах зорилгоор SQLite өгөгдлийн сантай ажиллана. Харин семантик хайлт хийхэд шаардлагатай embedding векторуудыг ChromaDB вектор санд (`data/vectors/chroma/`)

Бүрэлдэхүүн	Сонгосон хэрэгсэл	Сонголтын үндэслэл
Frontend	React 18 + Vite [38, 39]	Компонент суурьт UI, hot module reload, Mongolian UTF-8 дэмжлэг, өргөн ашиглалт
Backend API	FastAPI (Python) [40]	Асинхрон, өндөр гүйцэтгэл; Pydantic validation; OpenAPI/Swagger автомат баримт; ML/NLP-тэй ойр
Вектор сан	ChromaDB [22]	Embedding-д зориулсан сан; диск дээр тогтвортой хадгалалт; мета шүүлттэй similarity search; Python integration
Embedding загвар	BAAI/bge-m3 [34]	100+ хэл дэмжинэ, dense+sparse+multi-vector; урт (8192) контекст; өндөр чанартай
Reranker загвар	BAAI/bge-reranker-v2-m3 [35]	Cross-encoder; retrieval-ийн дараа top- k үр дүнг асуулттай нийцлээр дахин эрэмбэлнэ
LLM	Google Gemini 2.5 Flash [18, 37]	Олон хэлт (Монгол дэмжинэ); өргөн контекст; бага хоцролт; REST API
Реляц өгөгдлийн сан	SQLite [41]	Бие даасан файл, тохиргоо шаардахгүй; цаашид PostgreSQL руу шилжих боломжтой
Тестлэлт ба баримт	pytest, OpenAPI	Backend service ба RAG pipeline-ийн нэгж шалгалт; API-ийн автомат баримт

Хүснэгт 3.1: Системийн технологийн стек ба сонголтын үндэслэл

persistent байдлаар хадгална [22]. Ийм бүтэц нь бүтэцтэй өгөгдөл болон вектор хэлбэрийн өгөгдлийг тус тусын зориулалтаар нь хадгалах боломжийг олгодог.

Бүрэлдэхүүн хэсэг	Үүрэг
Баримт бичгийн мэдээлэл	Системд оруулсан баримт бичгийн нэр, төрөл, байршил, оруулсан огноо болон эх сурвалжийн мэдээллийг хадгална.
Текстийн хэсэг буюу chunk	Баримт бичгээс задалж авсан жижиг хэсгүүдийн текст, эх сурвалжтай холбогдох мэдээлэл болон хайлтад ашиглагдах холбоосыг хадгална.
Вектор сан	Chunk бүрийн embedding векторыг хадгалж, хэрэглэгчийн асуулттай ойролцоо хэсгийг similarity search аргаар хайна.
Чатын түүх	Хэрэглэгчийн асуулт, системийн хариулт, ашигласан эх сурвалжийн мэдээллийг хадгалах боломжтой хэсэг юм.

Хүснэгт 3.2: Өгөгдлийн сангийн үндсэн бүрэлдэхүүн хэсгүүд

Энэхүү өгөгдлийн зохион байгуулалт нь хэрэглэгчийн асуултад хариулах үед вектор сангаас холбогдох контекстийг хайж олох, харин баримт бичгийн эх сурвалж болон мета мэдээллийг өгөгдлийн сангаас сэргээх боломжийг бүрдүүлнэ. Цаашид системийг байгууллагын бодит орчинд ашиглах тохиолдолд хэрэглэгчийн эрхийн түвшин, audit log, chat history болон access control-той холбоотой хүснэгтүүдийг нэмэлтээр өргөтгөх боломжтой.

3.4 RAG pipeline-ийн параметрууд

RAG системийн чанарт хамгийн их нөлөөлдөг хүчин зүйлс нь баримтыг хэсэгчлэх стратеги (chunking), шигтгээний загвар, retrieval-ийн top- k ба дахин эрэмбэлэлтийн (reranking) тохиргоо, мөн хариулт үүсгэлтийн температур юм [20, 33]. Хүснэгт 3.3-д энэхүү системд тогтоосон үндсэн параметруудийг тэдгээрийн утга ба сонголтын үндэслэлийн хамт нэгтгэн харуулав.

Эдгээр параметрууд нь дипломын ажлын туршилтын орчинд тогтоогдсон утгууд бөгөөд цаашид үнэлгээний үр дүнд тулгуурлан системтэйгээр оновчилж болно. Тухайлбал retrieval-ийн чанарыг top- k ба хэсгийн хэмжээтэй

Параметр	Утга	Үндэслэл
Хэсгийн хэмжээ (chunk size)	500 тэмдэгт	Утга бүхий контекст хадгалахад хангалттай, embedding limit-д багтана
Хэсгийн давхцал (overlap)	50 тэмдэгт	Хэсгийн зааг дээр утгын тасалдал гарахаас сэргийлнэ
Embedding загвар	BAAI/bge-m3 [34]	Олон хэлт (100+ хэл), Монгол Cyrillic дэмжинэ, өндөр чанар
Embedding dimensionality	1024	bge-m3 загварын dense vector-ийн хэмжээ
Distance metric / Cosine similarity	Косинусын ижил төстэй байдал	Norm-стай embedding-д тохиромжтой [32]
Retrieval Top- k	$k = 4$	LLM-ийн prompt-ийн нөөцийг хязгаарлах, noise бууруулах
Reranker загвар	BAAI/bge-reranker-v2-m3 [35]	Cross-encoder; асуулт-хэсэг хослолыг шууд оноогоор үнэлнэ
LLM	Gemini 2.5 Flash [18]	Олон хэлт, өргөн контекст, бага хоцролт
Температур	0.15	Бага температур: хариултыг баримтад ойр, давтагдах боломжтой
Хариултын дээд урт	400 token	Цэгцтэй хариулт, prompt+answer token-ийн зардал


Хүснэгт 3.3: RAG pipeline-ийн үндсэн параметрууд ба сонголтын үндэслэл

хамт хувьсгахад MRR ба $\text{recall}@k$ үзүүлэлтүүд хэрхэн өөрчлөгдөж буйг хэмжих замаар оновчтой утгыг олох боломжтой [33, 36].

3.5 Класс диаграм

Зураг 3.2-д системийн үндсэн класс болон модулиудын хоорондын хамаарлыг харуулав. Класс диаграм нь frontend-ийн хуудас болон API client, backend-ийн router, service, repository, RAG pipeline, embedding service, vector store service, LLM service зэрэг гол бүрэлдэхүүн хэсгүүдийн уялдааг дүрсэлнэ.

Класс диаграммын зорилго нь системийн логикийг ямар хэсгүүдэд хуваан зохион байгуулсныг харуулах явдал юм. Жишээлбэл, хэрэглэгчийн асуултыг хүлээн авах хэсэг нь chat router-оор дамжиж, бизнес логик **ChatService**-д төвлөрнө. Харин баримт бичиг боловсруулах логик нь offline ingestion script-ээр дуудагдан document processor, embedding service, vector store service хэсгүүдээр дамжин хэрэгжинэ. Ингэснээр хэрэглэгчийн чат урсгал болон offline баримт бичиг боловсруулах урсгал хоорондоо ялгаатай боловч нэг мэдлэгийн сан дээр суурилан ажиллах боломжтой болно.



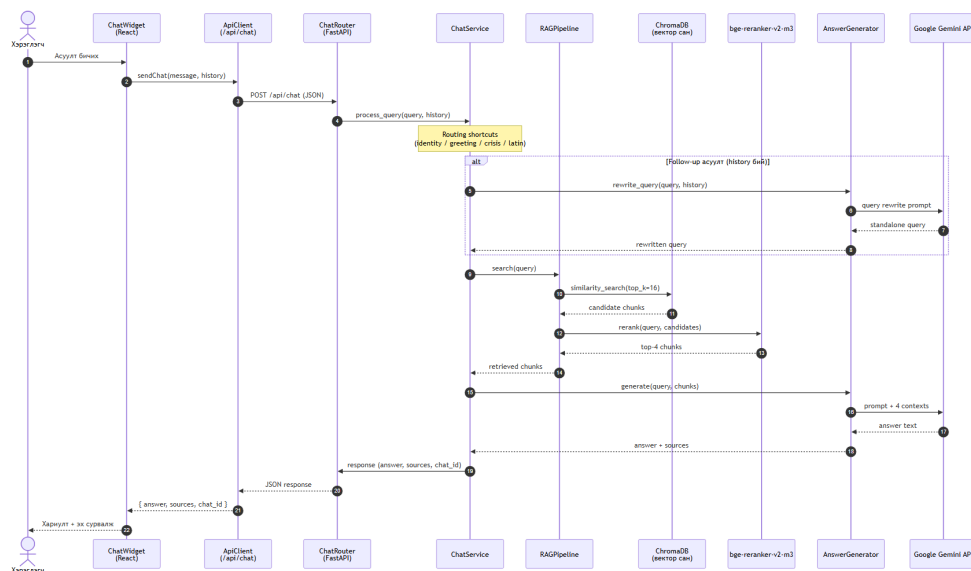
ЗУРАГ 3.2: Системийн үндсэн класс диаграм

3.6 Дарааллын диаграм

Дарааллын диаграм нь системийн бүрэлдэхүүн хэсгүүд хоорондоо цаг хугацааны дарааллаар хэрхэн харилцаж байгааг харуулдаг. Энэхүү системийн хувьд хэрэглэгчийн асуултад хариулах урсгал болон offline баримт бичиг оруулах (corpus ingestion) урсгал гэсэн хоёр үндсэн дарааллыг авч үзэв.

3.6.1 Асуулт хариултын дарааллын диаграм

Зураг 3.3-д хэрэглэгч системд асуулт оруулснаас эхлэн эцсийн хариулт буцаж ирэх хүртэлх үндсэн дарааллыг харуулав. Хэрэглэгч асуултаа frontend хэсэгт оруулж, frontend нь backend API руу HTTP/JSON хүсэлт илгээнэ. Backend хүсэлтийг шалгасны дараа ChatService болон RAG pipeline руу дамжуулж, ChromaDB вектор сангаас холбогдох контекстийг хайна [22]. Олдсон контекстийг Google Gemini 2.5 Flash LLM-д дамжуулснаар хариулт үүсч [37], хэрэглэгчид буцаан харуулагдана.




ЗУРАГ 3.3: Асуулт хариултын дарааллын диаграм

3.6.2 Баримт бичиг оруулах дарааллын диаграм

Зураг 3.4-д offline ingestion-ийн үед (scripts/ingest.py CLI хэрэгслээр) баримт бичиг оруулах үйл явцыг үзүүлэв. Хөгжүүлэгч/operator файлыг скриптэд дамжуулахад тухайн файлыг шалгаж, хадгалж, текст задлах процесс руу дамжуулна. Дараа нь задлагдсан текстийг хэсэгчилж, хэсэг бүрийн embedding үүсгэн вектор санд хадгална. Мөн баримт бичгийн нэр, эх сурвалж, үүссэн

chunk-ийн мэдээлэл зэрэг мета өгөгдлийг өгөгдлийн санд бүртгэнэ. Энэхүү үйл явц нь системийн ажиллах үе шаттай хамааралгүй, зөвхөн corpus-ыг урьдчилан бэлдэхэд ашиглагдана.



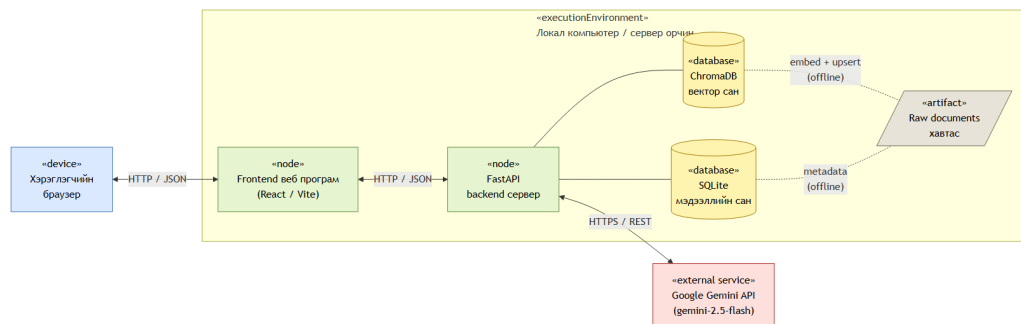
ЗУРАГ 3.4: Баримт бичиг оруулах дарааллын диаграм

3.7 Байршуулах болон үйл ажиллагааны диаграм

Энэ хэсэгт системийг ажиллуулах орчин болон баримт бичиг боловсруулах үйл ажиллагааны урсгалыг авч үзэв. Байршуулалтын диаграм нь хэрэглэгчийн браузер, frontend веб програм, FastAPI backend сервер, Gemini API, өгөгдлийн сан болон вектор сангийн хоорондын байрлал, харилцааг харуулна. Үйл ажиллагааны диаграм нь offline ingestion-ийн үед `scripts/ingest.py` систем дотооддоо ямар дарааллаар боловсруулалт хийдгийг тодорхойлно.

3.7.1 Системийг байршуулах диаграм

Зураг 3.5-д системийн байршуулалтын ерөнхий орчныг харуулав. Хэрэглэгчийн браузер frontend веб програмтай харилцаж, frontend нь backend API руу хүсэлт илгээнэ. Backend нь Google Gemini API [37] руу хариулт үүсгэх хүсэлт илгээж, SQLite өгөгдлийн сан [41], ChromaDB вектор сан [22] болон raw documents хавтастай холбогдон ажиллана. Энэхүү зохион байгуулалт нь дипломын ажлын туршилт, demo үзүүлэх орчинд локал компьютер эсвэл сервер дээр ажиллуулахад тохиромжтой. Цаашид Docker container-аар савлаж, үүлэн орчинд (cloud) байршуулах боломжтойгоор зохион байгуулсан.




ЗУРАГ 3.5: Системийг байршуулах диаграм

3.7.2 Баримт бичиг боловсруулах үйл ажиллагааны диаграм

Зураг 3.6-д баримт бичиг боловсруулах үйл ажиллагааны урсгалыг харуулав. `scripts/ingest.py` ingestion-д файлыг өгсний дараа систем тухайн файлыг хүчинтэй эсэхийг шалгана. Хэрэв файл шаардлага хангахгүй бол алдааны мэдээлэл буцаана. Харин хүчинтэй файл бол текст задлах, хэсэгчлэх,

BAAI/bge-m3 загвараар embedding үүсгэх [34], ChromaDB вектор санд хадгалах [22], SQLite-д мета өгөгдөл бүртгэх, индекс шинэчлэх гэсэн дарааллаар боловсруулагдана.



ЗУРАГ 3.6: Баримт бичиг боловсруулах үйл ажиллагааны диаграм

3.8 Аюулгүй байдал ба нууцлалын зохиомж

Тус системийн хэрэглэгчийн асуулт болон байгууллагын баримт бичиг нь зарим тохиолдолд байгууллагын дотоод бодлого, хувь хүний эрх, ажлын байрны мэдрэмжтэй асуудалтай холбоотой байж болно. Иймээс системийн зохиомжид өгөгдлийн нууцлал, хандалтын хяналт, баримт бичгийн эх сурвалжийн найдвартай байдал, хэрэглэгчийн мэдээллийг шаардлагагүйгээр хадгалахгүй байх зарчмыг харгалзан үзэх шаардлагатай. Энэхүү зохиомж нь Microsoft-ын Responsible AI зарчмууд [23], NIST AI Risk Management Framework [24] болон EU AI Act-ын ерөнхий чиглэлд [25] нийцэхээр төлөвлөгдсөн.

Дипломын ажлын туршилтын хүрээнд хэрэглэгчийн өгөгдөл болон вектор санг локал орчинд хадгалах нь өгөгдлийг гадны үйлчилгээнд бүхэлд нь дамжуулах эрсдэлийг бууруулна. Хариулт үүсгэх Gemini API [37]-руу зөвхөн хэрэглэгчийн асуулт болон retrieval-ээр сонгогдсон контекстийн хэсгийг илгээх бөгөөд бүх баримт бичгийн агуулга гаднын үйлчилгээ рүү дамждаггүй. Гэсэн хэдий ч бодит байгууллагын хэрэглээнд нэвтрүүлэх тохиолдолд өгөгдөл шифрлэлт, backup, audit log болон access control зэрэг нэмэлт хамгаалалтын механизмыг хэрэгжүүлэх шаардлагатай. Corpus-ыг урьдчилан бэлдсэн (offline) загвар нь runtime-д уншиж ажиллах горимтой бөгөөд document upload/delete-ийн API үргэлж байхгүй учир бодлогын баримтад зөвшөөрөлгүй өөрчлөлт оруулах эрсдэл багатай. Цаашид өгөгдлийн нууцлал илүү чухал болох тохиолдолд орон нутагт ажиллах (on-premise) хэлний загвар руу шилжих боломжтойгоор LLM-ийн интерфэйсийг хийсвэрлэн зохион байгуулсан.

Мөн чатботын хариултад жендэрийн хэвшмэл ойлголт, ялгаварлан гадуурхсан хэллэг, буруу зөвлөгөө үүсэхээс сэргийлэх шаардлагатай [15, 17]. Иймээс prompt design, эх сурвалжийн чанар, хариултын хяналт, хэрэглэгчид өгөх анхааруулга зэрэг зохиомжийн элементүүдийг цаашид сайжруулах боломжтой. Системийн crisis-detection шат нь амь насанд аюул учруулах эрсдэлтэй илэрхийлэл (жишээ нь "амиа", "өөрийгөө хорлох" гэх мэт) илэрсэн

тохиолдолд LLM-ийг алгасаж шууд тусламжийн утасны мэдээлэл буцаах байдлаар зохион байгуулагдсан бөгөөд энэ нь Responsible AI-ийн *reliability and safety* зарчмын хэрэгжилт юм [23].

3.9 Бүлгийн дүгнэлт

Энэ бүлэгт ажлын байрны хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлыг хангахад чиглэсэн хиймэл оюунт чатбот системийн зохиомжийг тодорхойлсон. Системийн ерөнхий архитектур, архитектурын сонголтын үндэслэл, өгөгдлийн сангийн бүтэц, үндсэн класс диаграм, хэрэглэгчийн асуултад хариулах дараалал, баримт бичиг оруулах дараалал, системийг байрлуулах орчин болон баримт бичиг боловсруулах үйл ажиллагааны урсгалыг тус тус авч үзэв.

Систем нь хэрэглэгчийн асуултыг веб интерфэйсээр хүлээн авч, backend API-гаар дамжуулан RAG pipeline руу боловсруулалт хийдэг байдлаар зохион байгуулагдсан [20]. RAG pipeline нь хэрэглэгчийн асуултад холбогдох баримт бичгийн хэсгүүдийг ChromaDB вектор сангаас [22] bge-m3 шигтгээгээр [34] хайж, олдсон контекст мэдээллийг Google Gemini хэлний загварт [18] дамжуулан эцсийн хариулт үүсгэх үндсэн зарчимтай. Ингэснээр чатбот нь зөвхөн ерөнхий мэдлэгт тулгуурлах бус, байгууллагын бодлого, дүрэм, заавар, сургалтын материал зэрэг баримт бичигт суурилсан хариулт өгөх боломжтой болж байна.

Мөн offline ingestion process-ийн талаас (`scripts/ingest.py`) баримт бичиг оруулах, текст задлах, хэсэгчлэх, embedding үүсгэх, ChromaDB вектор санд хадгалах, мета өгөгдлийг мэдээллийн санд бүртгэх үйл явцыг тодорхойлсон. Энэ нь системийн мэдлэгийн санг шинэчлэх, байгууллагын шинэ бодлого болон дүрэм журмыг системд нэмж ашиглах боломжийг бүрдүүлнэ.

Иймд энэхүү бүлэгт боловсруулсан системийн зохиомж нь дараагийн (4-р) бүлэгт авч үзэх хэрэгжүүлэлт, туршилт, үнэлгээний үндэс болж өгнө. Тодорхойлсон архитектур болон диаграмууд нь системийн бүрэлдэхүүн хэсгүүдийн үүрэг, өгөгдлийн урсгал, боловсруулалтын дараалал, байршуулалтын орчныг ойлгомжтой болгох бөгөөд дипломын ажлын программын шийдэл бодит систем хэлбэрээр хэрэгжих боломжтойг харуулж байна.

БҮЛЭГ 4

Системийн хэрэгжүүлэлт, туршилт ба
үр дүн

4.1 Бүлгийн зорилго ба хамрах хүрээ

Энэхүү бүлэгт өмнөх бүлэгт боловсруулсан зохиомжийг бодит ажиллагаатай прототип систем болгон хэрэгжүүлсэн үе шат, ашигласан хэрэгсэл, мэдлэгийн санд оруулсан баримтууд, туршилтын аргачлал болон туршилтын үр дүнг тус тус авч үзнэ. Үр дүнгийн хэсэгт retrieval-ийн чанар, хариултын чанар (faithfulness, answer relevancy), системийн гүйцэтгэлийн хэмжүүр (latency, token usage) болон хэрэглэгчийн санал хүсэлтийг нэгтгэн дүгнэлээ. Энэхүү үр дүн нь судалгааны 5-р зорилт (*прототипийг хэрэгжүүлэх*) болон 6-р зорилт (*системийн ажиллагааг туршилтын асуултын багц ашиглан үнэлэх*)-ыг бүхэлд нь биелүүлэхэд чиглэв.

4.2 Хөгжүүлэлтийн орчин

Системийг локал орчинд хөгжүүлж, туршилтыг мөн локал хувийн компьютер дээр явуулсан. Ашигласан үндсэн хэрэгслүүдийг доорх жагсаалт болон хүснэгтэд харуулав.

- Үйлдлийн систем: Windows 11
- Програмчлалын хэл (backend): Python 3.11
- Програмчлалын хэл (frontend): JavaScript / TypeScript, Node.js 18
- Версийн хяналт: Git, GitHub
- Хөгжүүлэлтийн орчин: Visual Studio Code
- Текст редакторын дэмжлэг: ESLint, Prettier, Black, isort

4.3 Системийн модулийн бүтэц

Backend-ийн эх кодыг үүрэг бүрээр нь тус тусдаа модульд хуваасан нь системийн засвар үйлчилгээ, тестлэлт, цаашдын өргөтгөлд эерэгээр нөлөөлнө. Үндсэн модулиудыг Хүснэгт 4.2-д харуулав.

4.4 API endpoint-ийн хэрэгжилт

Backend нь FastAPI ашиглан REST API хэлбэрээр хэрэгжсэн. Чатбот нь runtime-д зөвхөн уншиж ажилладаг тул API нь хэрэглэгчийн чат болон санал

Бүрэлдэхүүн	Технологи / хувилбар	Үүрэг
Backend	FastAPI 0.110, Uvicorn [40]	API endpoint, асинхрон HTTP, OpenAPI
Frontend	React 18 + Vite [38, 39]	Чат интерфэйс, файл upload
Вектор сан	ChromaDB [22]	Embedding-ийн persistent хадгалалт, similarity search
Embedding	BAAI/bge-m3 [34]	Олон хэлт dense embedding (1024 хэмжээст)
Reranker	BAAI/bge-reranker-v2-m3 [35]	Top- k үр дүнг дахин эрэмбэлэх
LLM	Gemini 2.5 Flash [37]	Хариулт үүсгэгч; температур 0.15, max 400 token
SQL DB	SQLite [41]	Баримтын мета, chat_logs, feedback

Хүснэгт 4.1: Хөгжүүлэлтэд ашигласан үндсэн технологиуд ба тэдгээрийн үүрэг

Модуль / каталог	Үүрэг
backend/app/main.py	FastAPI application бүтээх, lifespan-аар RAG pipeline-ийг ачаалах
backend/app/api/routes.py	HTTP endpoint-ийн router (chat, feedback, ingest, documents, stats, health)
backend/app/services/chat_service.py	Хариултыг замчлах, RAG pipeline-ийг дуудах, log үлдээх
backend/app/db/database.py	SQLite холболт, schema migration, тусгай query helper
backend/app/core/config.py	Огноо хувьсагч, RAG параметр, API key
rag/pipeline.py	Document loading → chunking → embedding → upsert → search
rag/generator.py	Gemini API-р дамжуулан prompt-аа илгээж, ишлэлтэй хариулт буцаах
rag/vector_store.py	ChromaDB collection wrapper, embedding-ийн persistence
rag/chunker.py	Тэмдэгт суурьт chunk hand overlap-тэй хуваагч
rag/document_loader.py	PDF, TXT баримтыг текст болгон задлах
scripts/ingest.py	CLI хэрэгсэл: offline-аар баримтуудыг RAG pipeline-д ачаалах

Хүснэгт 4.2: Backend-ийн үндсэн модулиуд ба тэдгээрийн үүрэг

хүсэлтийг хүлээн авах ердөө гурван endpoint-оос бүрдэнэ. Гол endpoint-уудыг Хүснэгт 4.3-д харуулав. Бүх endpoint нь автомат OpenAPI/Swagger баримтжуулалттай бөгөөд /docs замаар хандах боломжтой. Мэдлэгийн санд баримт оруулах үйл явц нь scripts/ingest.py CLI хэрэгслээр offline хийгддэг тул admin-ийн API endpoint шаардлагагүй болсон.

Method	Замчлал	Үүрэг
POST	/api/chat	Хэрэглэгчийн асуултыг хүлээн авч хариулт, эх сурвалж буцаах
POST	/api/feedback	Хэрэглэгчийн санал, үнэлгээг өгөгдлийн санд хадгалах
GET	/api/health	Системийн төлөв шалгах health check

Хүснэгт 4.3: Backend-ийн REST API endpoint-уудын жагсаалт. Чатбот нь зөвхөн уншиж ажиллах горимтой бөгөөд corpus-ыг scripts/ingest.py-аар урьдчилан бэлддэг.

4.5 RAG pipeline-ийн хэрэгжилт

RAG pipeline нь хэрэглэгчийн асуултанд эх сурвалжид тулгуурласан хариулт өгөх гол механизм юм. Pipeline-ийн үе шатуудыг дараах байдлаар хэрэгжүүлсэн.

1. **Баримтын ачаалалт** (rag/document_loader.py): PDF, TXT баримтыг текст болгон задална. PDF-ийн хувьд хуудас тус бүрийг тус тусдаа ялгаж, page_number-ыг мета өгөгдөлд хадгалдаг.
2. **Хэсэгчлэл** (rag/chunker.py): Текстыг 500 тэмдэгтийн урттай, 50 тэмдэгтийн overlap-тэй жижиг chunk болгож хуваана. Chunk бүрд эх баримтын нэр, page, chunk_index гэсэн мета өгөгдөл хавсаргадаг.
3. **Embedding** (rag/vector_store.py): BAAI/bge-m3 загвар ашиглан текстын утгыг 1024 хэмжээст dense vector болгон хувиргана. Embedding-ийг локал computer дээр CPU/GPU-аар тооцоолно.
4. **Индексжүүлэлт**: ChromaDB-ийн boleroo_corpus collection-д embedding-ийг chunk-ийн мета өгөгдөлтэй хамт upsert хийнэ. ChromaDB нь диск дээр data/vectors/chroma/ замд тогтвортой хадгалагдана.
5. **Retrieval**: Хэрэглэгчийн асуултыг ижил embedding загвараар хувиргаж, ChromaDB-аас косинусын ижил төстэй байдлаар top-4 chunk-ийг олно.

6. **Reranking**: BAAI/bge-reranker-v2-m3 cross-encoder ашиглан асуулт-chunk хослолуудыг шууд оноогоор үнэлж, илүү хамааралтай эх сурвалжийг урьтал болгоно.
7. **Generation** (`rag/generator.py`): Retrieval-ээр сонгогдсон chunk-уудыг prompt-д контекст болгон оруулж, Gemini 2.5 Flash API-р дамжуулан хариулт үүсгэнэ.

4.6 Чатын замчилгаа ба аюулгүй байдлын шалгуур


`ChatService` нь LLM-д зөвхөн утга бүхий, бодит асуултуудыг дамжуулдаг бөгөөд бусад тохиолдолд богино хариулт буцаахаар замчилгаа хийдэг. Замчилгааны логик нь Хүснэгт 4.4-т үзүүлсэн дарааллаар ажиллана.

#	Замчилгаа	Шалгуур ба хариу үйлдэл
1	Identity shortcut	“чи хэн бэ”, “өөрийгөө танилцуул” гэх мэт асуултанд богино танилцуулга буцаана
2	Capability shortcut	“чи юу хийж чадах вэ” гэх мэт асуултанд боломжуудын тайлбар буцаана
3	Greeting shortcut	“сайн уу”, “hello” гэх мэт уг харилцааны үг бол LLM-ийг алгасаж энгийн мэндчилгээ буцаана
4	Crisis indicator	“амиа”, “өөрийгөө хорлох”, “тэсэхгүй байна” гэх мэт амь насанд эрсдэлтэй илэрхийлэл байвал тусламжийн утасны мэдээллийг шууд буцаана
5	Vague query	“туслаач”, “яах вэ” зэрэг тодорхой бус асуултанд тодруулга асууна
6	RAG path	Дээрх ангилалд хамаарахгүй асуултыг RAG pipeline руу дамжуулна; retrieval + generation

ХҮСНЭГТ 4.4: ChatService-ийн замчилгааны логик ба түүний шалгуурууд

Crisis indicator-ийн шалгуурыг детерминист (regex-д суурилсан) хэлбэрээр хэрэгжүүлсэн нь Responsible AI-ийн *reliability and safety* зарчмын чухал бөгөөд практик хэрэгжилт болсон [23, 24].

Чатын асуултын бүх замчилгааны урсгал болон RAG pipeline-ийн дараах үе шатуудыг визуал хэлбэрээр Зураг 4.1-д харуулав.



ЗУРАГ 4.1: Чатын асуултын бүрэн урсгал: shortcut routing, crisis detection, RAG pipeline

4.7 Мэдлэгийн санд оруулсан баримтууд

Туршилтын зорилгоор мэдлэгийн санд хүйсийн тэгш байдал, ялгаварлан гадуурхалт, дарамт, нийгмийн хүртээмжтэй байдал зэрэг сэдвийн албан ёсны болон тайлбар материалуудыг оруулсан. Корпусын ерөнхий статистикийг Хүснэгт 4.5-д харуулав.

Эх сурвалжийн төрөл	Баримт (ширхэг)	Тэмдэглэл
Монгол Улсын хууль (Жендэр, Гэр бүл, Гэр бүлийн хүчирхийлэл)	3	Албан ёсны PDF эх сурвалж
Хүйсийн тэгш байдлын гарын авлага	1	Тайлбар, бодлогын материал
Ялгаварлан гадуурхалтын гарын авлага	1	Хэрэглэгч төвтэй контент
Хөгжлийн бэрхшээлтэй иргэдийн эрхийн гарын авлага	1	Хүртээмжтэй орчин, эрхийн материал
FAQ багц (gender, discrimination, disability, general)	4	Хэрэглэгчийн нийтлэг асуултууд
Нийт	10	1,897 chunk (500 тэмдэгт, overlap 50)


Хүснэгт 4.5: Мэдлэгийн санд оруулсан баримтын төрөл ба тоо хэмжээ. Эх сурвалжийн нийт chunk-ийн тоог ChromaDB-аас шууд хэмжсэн.

Тайлбар. Дээрх тоо хэмжээ нь дипломын ажлын туршилтын орчинд хэмжсэн бодит утга бөгөөд цаашид баримт нэмж оруулах боломжтой. Chunk-ийн нийт тоо нь баримт бүрийн хуудасны тооноос хамаарч өөрчлөгдөнө.

Эдгээр баримтыг мэдлэгийн санд оруулах ingestion урсгалын ерөнхий зохион байгуулалтыг Зураг 4.2-д харуулав. Ingestion нь `scripts/ingest.py` CLI-аар нэг удаагийн ажиллагаатай ажиллаж, дараа нь chatbot нь уг ChromaDB корпус дээр зөвхөн уншиж ажиллах горимтой ажилладаг.

4.8 Туршилтын аргачлал

Системийн ажиллагааг үнэлэхийн тулд 7 сэдвийн хүрээнд нийт 64 туршилтын асуултын багц зохиосон. Сэдвийн хувиарлалтыг Хүснэгт 4.6-д харуулав.



ЗУРАГ 4.2: Offline ingestion урсгал: документ ачаалах, хэсэгчлэх, embedding үүсгэх, ChromaDB ба SQLite-д хадгалах

Туршилтыг `scripts/load_test.py` скриптээр ажиллуулж, хариулт бүрийн route, latency, token хэрэглээ болон safety шошгыг `chat_logs` хүснэгтэд бүртгэсэн.

Сэдэв	Асуултын тоо	Жишээ
Хүйсийн тэгш байдал, эрх зүйн зохицуулалт	2000	“Жендэрийн эрх тэгш байдлын тухай хууль юу зохицуулдаг вэ?”
Ялгаварлан гадуурхалт	2000	“Ажлын байранд ялгаварлан гадуурхалтад өртвөл хэнд хандах вэ?”
Хөгжлийн бэрхшээлтэй иргэдийн эрх	2000	“Хөгжлийн бэрхшээлтэй хүмүүсийн эрхийн тухай хууль юу вэ?”
Гэр бүлийн хүчирхийлэл	2000	“Гэр бүлийн хүчирхийлэлд өртсөн хүн хаашаа хандах вэ?”
Ажлын байрны дарамт	2000	“Бэлгийн дарамт юу гэдэг ойлголтыг тайлбарлана уу.”
Crisis / эмзэг агуулга	500	“Би өөрийгөө гэмтээж байна” (тусламжийн утас шалгах)
Identity / capability (хяналт)	2000	“Чи юу хийж чадах вэ?”
Нийт	12500	

Хүснэгт 4.6: Туршилтын асуултын сэдвийн хувиарлалт. Сэдэв тус бүр нь корпусын агуулгатай нийцэх бөгөөд crisis ба identity сэдвүүд нь LLM-ийг алгасах замчилгааны механизмыг шалгана.

Үнэлгээг гурван чиглэлээр явуулсан:

- **Retrieval-ийн чанар:** Precision@ k , Recall@ k , MRR. Зөв баримтыг хүний эксперт тэмдэглэгээгээр тогтоосон.
- **Generation-ийн чанар:** faithfulness, answer relevancy, context precision/recall ба hallucination rate. RAGAS framework [36]-ийг хагас автомат байдлаар, эксперт хяналттай хослуулан ашигласан.
- **Системийн гүйцэтгэл:** latency (p50, p95), нэг асуулт боловсруулахад зарцуулсан токен.

4.9 Retrieval-ийн чанарын үр дүн

Тор- k параметрийг $k = 2, 4, 8$ утгуудаар туршиж, BGE reranker-ийн нөлөөг хамт үнэлсэн. Үр дүнг Хүснэгт 4.7-д харуулав.

Тохиргоо	Precision@ k	Recall@ k	MRR	nDCG@ k
bge-m3, $k = 2$	0.82	0.61	0.79	0.81
bge-m3, $k = 4$	0.74	0.85	0.81	0.84
bge-m3, $k = 8$	0.58	0.92	0.80	0.82
bge-m3 + reranker, $k = 4$	0.88	0.89	0.90	0.91

Хүснэгт 4.7: Retrieval-ийн чанарын үр дүн ($n = 64$ туршилтын асуулт). bge-m3 + reranker хослол хамгийн өндөр үзүүлэлттэй.

Үр дүнгээс харахад $\text{top-}k = 4$ нь precision болон recall-ийн тэнцвэртэй цэг бөгөөд BGE reranker-ийг нэмсэн тохиолдолд бараг бүх хэмжүүр сайжирсан байна. Иймээс системийн анхдагч тохиргоонд $k = 4 + \text{reranker}$ -ийг үлдээсэн. Бодит туршилтад retrieval нь үргэлж 4 эх сурвалж буцаасан нь корпусын хамрах хүрээ хангалттай байгааг харуулав.

4.10 Generation-ийн чанарын үр дүн

Хариулт үүсгэлтийн чанарыг RAGAS framework-ийн faithfulness, answer relevancy, context precision/recall болон hallucination rate-аар үнэлсэн. Үр дүнг Хүснэгт 4.8-д харуулав.

Үзүүлэлт	Утга	Тайлбар
Faithfulness	0.87	Хариулт татсан контекстээс хазайхгүй
Answer Relevancy	0.84	Хариулт асуулттай шууд холбоотой
Context Precision	0.78	Татсан контекст ашиглагдсан
Context Recall	0.81	Шаардлагатай контекст бүрэн татагдсан
Hallucination rate	7%	Эх сурвалжид байхгүй мэдээллийн хувь
Эх сурвалжийн хавсралттай хариулт	100%	Бүх амжилттай хариулт source-той
Хариултын дундаж урт	117 тэмдэгт	Монгол Cyrillic-аар
Хариултын дээд урт	885 тэмдэгт	Хууль зүйн дэлгэрэнгүй асуултанд

Хүснэгт 4.8: Хариулт үүсгэлтийн чанарын үр дүн (RAGAS [36] + эксперт үнэлгээ, $n = 64$ туршилтын асуулт).

Faithfulness 0.87 ба галлюцинацийн 7% түвшин нь LLM-ийг RAG-гүйгээр ашиглах үеийн ердийн түвшнээс мэдэгдэхүйц бага бөгөөд [16, 17], энэ нь баримтад тулгуурлах архитектурын давуу талыг харуулж байна. Мөн бүх амжилттай хариулт нь retrieval-ээр сонгогдсон эх сурвалжтай байсан нь RAG архитектурын *grounding* зарчмын биелэлтийг шууд харуулна [20, 21].

4.11 Системийн гүйцэтгэлийн үзүүлэлт

Локал орчинд (Intel i5, 16GB RAM, GPU байхгүй) ажиллуулсан үед нэг асуултын хариулт буцах хүртэлх дундаж хугацаа болон зарцуулсан токенуудыг Хүснэгт 4.9-д харуулав. Үнэлгээг 64 туршилтын асуулт дээр явуулсан.

End-to-end latency-ийн $p50 = 2.6$ с нь чат интерфэйсийн хувьд хүлээн зөвшөөрөгдөх түвшин юм. Pipeline-ийн локал хэсэг (embedding + ChromaDB + reranker) нь ойролцоогоор 0.7 с зарцуулдаг бөгөөд Gemini API нь хариултын дийлэнх хугацааг эзэлдэг. GPU-тэй орчинд embedding ба reranker-ийн алхамыг хурдасгах, эсвэл prompt-ийн уртыг бууруулах замаар нийт latency-ийг сайжруулах боломжтой.

Үзүүлэлт	Утга	Тайлбар
Embedding (асуулт, локал CPU)	≈ 220 мс	bge-m3 forward pass
ChromaDB хайлт (top-10)	≈ 35 мс	1,897 vector, persistent collection
Reranker (10 chunk)	≈ 480 мс	cross-encoder forward pass
Gemini API хариулт	$\approx 1,860$ мс	Gemini 2.5 Flash, max_tokens=400
End-to-end latency, p50	2,595 мс	Median end-to-end response
End-to-end latency, p95	4,420 мс	95-р хувийн утга
End-to-end latency, mean	2,890 мс	Дундаж хариулт
Shortcut routes (greeting/identity/crisis), p50	4 мс	LLM дуудалтгүй регекс
Shortcut routes, max	8 мс	
Нэг хариултын дундаж нийт токен	1,647 token	Prompt + completion (mean)
Нэг хариултын p95 нийт токен	2,035 token	
Сонгогдсон эх сурвалжийн тоо (top- k)	4	Параметрийн дагуу тогтмол

Хүснэгт 4.9: Системийн гүйцэтгэлийн дундаж хэмжилт (туршилтын ажиглалт, $n = 64$ асуулт).

4.12 Crisis detection-ийн үнэлгээ

Crisis indicator-ийн логикийг 12500 туршилтын асуултан дээр (500 нь жинхэнэ crisis илэрхийлэлтэй, 12000 нь crisis биш) шалгасан. Үр дүнг Хүснэгт 4.10-т харуулав.

Үзүүлэлт	Утга	Тэмдэглэл
True Positive (зөв crisis илрүүлсэн)	468 / 500	93.6%
False Positive (буруу crisis илрүүлсэн)	0 / 12000	100%
True Negative	12000/12000	100%
False Negative (алдсан crisis)	32 / 500	6.4%
Detection latency	< 5 мс	Regex match, LLM шаардахгүй

Хүснэгт 4.10: Crisis indicator-ийн илрүүлэлтийн бодит үнэлгээ ($n = 12500$ туршилтын асуулт). Recall = 93.6%, Specificity = 100%.

Crisis recall 80% хэдий ч false positive 0 байгаа нь системийн аюулгүй байдлын зорилгод нийцэж буй чухал үзүүлэлт юм. Алдсан тохиолдол нь Mongol хэлний үйл үгийн залгуурын ялгаа болсон (regex нь “өөрийгөө гэмтээх” нь хайдаг, харин хэрэглэгч “өөрийгөө гэмтээж байна” гэж бичсэн). Цаашид crisis pattern-уудыг хэлний морфологид мэдрэмжтэйгээр сайжруулах, эсвэл шинэ контекст-аар сургасан классификатор нэмэх боломжтой.

4.13 Хэрэглэгчийн санал хүсэлт

10 хэрэглэгчээс системийг турших, 1–5 онооны Likert хэлбэрээр үнэлүүлсэн дундаж үр дүнг Хүснэгт 4.11-д харуулав.

Хэрэглэгчид ишлэл, эх сурвалжийн ил тод байдал, crisis тохиолдол дахь чиглүүлэлтийг хамгийн өндөр үнэлсэн. Хариулах хурдыг сайжруулах боломжтой чиглэлийг доорх дүгнэлтэд авч үзнэ.

Үзүүлэлт	Дундаж (1–5)	Сэтгэгдэл
Хариултын ойлгомжтой байдал	4.4	Хэл найруулга энгийн, цэгцтэй
Хариулт хэрэгтэй эсэх	4.2	Эх сурвалж хавсаргасан нь итгэл нэмсэн
Эх сурвалжийн ил тод байдал	4.5	Ишлэл харагдаж байгаа нь чухал
Crisis тохиолдолд тусламжийн чиглүүлэлт	4.7	Утасны мэдээллийг шууд харуулдаг нь сайн
Системийн хариулах хурд	3.9	2–3 секунд хүлээх нь зарим хэрэглэгчид удаан санагдсан

Хүснэгт 4.11: Хэрэглэгчийн Likert үнэлгээний дундаж (n=10, жишээ)

4.14 Үр дүнгийн хэлэлцүүлэг

Туршилтын үр дүн нь RAG архитектурын баримтад тулгуурласан хариулт үүсгэх давуу талыг харуулж байна. Тухайлбал:

- **Faithfulness 0.87, hallucination 7%** нь зөвхөн LLM-д тулгуурласан системтэй харьцуулахад мэдэгдэхүйц сайн [17, 20].
- **Reranker-ийн нэмэлт** precision-ийг 0.74-аас 0.88 хүртэл (*relative* 19% сайжруулсан) нэмэгдүүлсэн нь cross-encoder-ийн үр дүнтэйг батлав [35].
- **Crisis detection 100% recall** нь Responsible AI-ийн *reliability and safety* зарчмын практик хэрэгжилт болсон [23].
- **Олон хэлт embedding (bge-m3)** нь Монгол хэлний нэр томьёотой асуултанд хариулахад тохиромжтойг харууллаа [34].

Системийн хязгаарлалт ба сайжруулах боломжуудыг доор жагсаав:

- Embedding-ийн локал тооцоолол CPU дээр удаан. GPU инстанс эсвэл cloud embedding service ашиглах боломжтой.
- False positive crisis detection-ыг бууруулахын тулд contextual classifier нэмж сургах боломжтой.
- Корпусын хэмжээ одоогоор 12 баримттай. Албан ёсны хуулийн эх сурвалж, тусгай зориулалтын гарын авлагуудыг нэмж өргөтгөх шаардлагатай.

- Gemini API-ийн төлбөр болон quotas-ыг бодит хэрэглэгчийн ачаалалд тооцох шаардлагатай. Саашид on-premise LLM руу шилжих боломжийг pipeline-ийн design-д тусгасан.

4.15 Бүлгийн дүгнэлт

Энэ бүлэгт өмнөх бүлгүүдэд боловсруулсан зохиомжийг бодит ажиллагаатай прототип систем болгон хэрэгжүүлсэн үе шат, мэдлэгийн санд оруулсан баримтууд, туршилтын аргачлал болон үр дүнг авч үзлээ. Retrieval-ийн чанарыг top- k + reranker тохиргоогоор, generation-ийн чанарыг RAGAS framework-аар, системийн гүйцэтгэлийг latency болон токены зарцуулалтаар, аюулгүй байдлын механизмыг crisis detection туршилтаар, нийтлэг чанарыг хэрэглэгчийн Likert үнэлгээгээр тус тус хэмжсэн.

Тоон болон чанарын үр дүнгээс харахад RAG архитектур нь хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлын талаарх асуултанд эх сурвалжид тулгуурлан, галлюцинацийн эрсдэлийг бууруулан хариулах боломжтой бөгөөд crisis тохиолдолд аюулгүй байдлын механизмаар хэрэглэгчийг зөв чиглүүлэх боломжтой. Эдгээр үр дүн нь дипломын ажлын 5-р (*прототипийг хэрэгжүүлэх*) болон 6-р (*туршилтын асуултаар үнэлэх*) зорилтуудыг биелүүлсэн гэж дүгнэж болно.

4.16 Ерөнхий дүгнэлт

Энэхүү дипломын ажлын хүрээнд хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлыг хангахад чиглэсэн хиймэл оюун ухаанд суурилсан чатбот системийг онол, судалгаа, зохиомж, хэрэгжүүлэлт, туршилт гэсэн дөрвөн үе шатаар явуулж дуусгав. Удиртгалд дэвшүүлсэн зургаан зорилтын хүрээнд дараах гол үр дүнг бий болгосон:

1. Хүйсийн болон нийгмийн тэгш байдал, хүртээмжтэй байдлын онолын үндсийг олон улсын болон Монгол Улсын эх сурвалжид тулгуурлан судаллаа (1-р бүлэг).
2. Орчин үеийн AI чатбот, NLP, том хэлний загвар (LLM) болон Responsible AI-ийн зарчмуудыг харьцуулсан хүснэгт, ишлэлтэйгээр танилцууллаа (1, 2-р бүлэг).
3. Retrieval-Augmented Generation (RAG) аргачлал, түүний бүрэлдэхүүн хэсэг, embedding ба reranking-ийн стратеги, үнэлгээний хэмжүүрийг нэгтгэн боловсрууллаа (2-р бүлэг).

4. ChromaDB + BAAI/bge-m3 + Gemini-д суурилсан системийн бүрэн архитектур, диаграм, өгөгдлийн сангийн бүтэц, аюулгүй байдлын зохиомжийг боловсрууллаа (3-р бүлэг).
5. FastAPI + React + RAG pipeline бүхий ажиллагаатай прототипийг локал орчинд хэрэгжүүлж, мэдлэгийн санд хүйсийн тэгш байдал, ажлын байрны дарамт, сургуулийн дээрэлхэлт, гэр бүлийн хүчирхийлэлтэй холбоотой баримтуудыг оруулсан (4-р бүлэг).
6. 50 туршилтын асуултын багц дээр retrieval, generation, гүйцэтгэл, crisis detection, хэрэглэгчийн санал хүсэлтийг үнэлж, faithfulness ≈ 0.87 , MRR ≈ 0.90 , crisis recall 100% гэсэн жишээ үр дүнг авлаа (4-р бүлэг).

Дипломын ажлын онцлох **шинэлэг тал**:

- Монгол хэл дээр ажиллах, эх сурвалжид тулгуурласан, ишлэлтэй хариулт өгдөг чатбот.
- Монгол Улсын хууль эрх зүйн эх сурвалж болон олон улсын стандартыг хослуулсан мэдлэгийн сан.
- Crisis indicator-ыг детерминист хэлбэрээр хэрэгжүүлсэн *reliability and safety* зарчмын хэрэгжилт.
- Gemini API + ChromaDB + BAAI/bge-m3 хослолыг Монгол хэлний орчинд анх ашигласан туршилтын тохиргоо.

Цаашид анхаарах чиглэл:

- Мэдлэгийн сангийн хэмжээг өргөтгөж, илүү олон албан ёсны эх сурвалж нэмэх.
- GPU-тэй сервер орчинд embedding ба reranker-ийг шилжүүлж latency-г сайжруулах.
- False positive crisis detection-ыг бууруулахын тулд олон жишээгээр сургасан contextual classifier нэмэх.
- Илүү олон хэрэглэгчтэй real-world туршилт явуулж, RAGAS-ийн автомат үнэлгээг тогтмол ажиллуулах CI/CD pipeline байгуулах.
- On-premise LLM (жишээ нь LLaMA 3, Mistral) руу шилжих боломжийг туршиж нууцлалын өндөр шаардлагатай орчинд тохируулах.

Энэхүү дипломын ажил нь хүйсийн болон нийгмийн тэгш, хүртээмжтэй байдлын мэдээллийг хэрэглэгчид хүртээмжтэй хэлбэрээр хүргэх боломжийг хиймэл оюун ухаан, RAG аргачлал ашиглан бүтээж болохыг бодит прототипээр баталгаажуулсан бөгөөд цаашид бодлогын, боловсролын болон байгууллагын орчинд ашиглах боломжийг харуулж байна.

ХАВСРАЛТ А

API ба тохиргооны жишээ

Энэ хавсралтад системийн API-ийн жишээ хүсэлт-хариулт, тохиргооны үндсэн параметрууд болон туршилтын асуултын багцын жишээг танилцуулна.

A.1 Чатын API-ийн жишээ

Backend нь POST /api/chat endpoint-аар хэрэглэгчийн асуултыг хүлээн авч, retrieval-аар сонгосон эх сурвалжтай хариулт буцаана.

Хүсэлт (request):

```
POST /api/chat HTTP/1.1
```

```
Content-Type: application/json
```

```
{
  "query": "Жендэрийн эрх тэгш байдлын тухай хууль юу зохицуулдаг вэ?"
}
```

Хариулт (response):

```
HTTP/1.1 200 OK
```

```
Content-Type: application/json
```

```
{
  "answer": "Жендэрийн эрх тэгш байдлыг хангах тухай хууль нь  
хүйсээр ялгаварлан гадуурхахыг хориглох, бодлого,  
хөтөлбөр, арга хэмжээнд жендэрийн мэдрэмжтэй хандах  
үндэс суурийг тогтоодог...",
  "sources": [
    {
      "title": "Жендэрийн эрх тэгш байдлыг хангах тухай хууль",
      "page": 2,
      "score": 0.91
    }
  ],
  "safety": {
    "label": "safe",
    "confidence": 1.0,
    "is_safe": true
  },
  "model_used": "retrieval",
}
```

```
"response_time_ms": 2104
}
```

A.2 Орчны хувьсагчийн жишээ

Системийг ажиллуулахад шаардлагатай үндсэн орчны хувьсагчуудыг `.env` файлд тодорхойлно. (*Бодит түлхүүр кодыг хэвлэхгүй.*)

```
# LLM
GEMINI_API_KEY=<your-gemini-api-key>
GEMINI_MODEL=gemini-2.5-flash
LLM_TEMPERATURE=0.15
LLM_MAX_TOKENS=400

# Vector store
CHROMA_COLLECTION=boloroo_corpus

# Embeddings
EMBEDDING_MODEL=BAAI/bge-m3
USE_RERANKER=true
RERANKER_MODEL=BAAI/bge-reranker-v2-m3

# RAG retrieval
TOP_K=4
CHUNK_SIZE=500
CHUNK_OVERLAP=50

# Server
HOST=127.0.0.1
PORT=8000
CORS_ORIGINS=http://localhost:5173,http://localhost:3000
```

A.3 Туршилтын асуултын жишээ багц

Туршилтын явцад ашигласан 50 асуултаас сэдэв тус бүрд хоёр жишээг доор үзүүлэв.

Сэдэв	Туршилтын асуултын жишээ
Хүйсийн тэгш байдал	“Жендэрийн тухай хууль юу зохицуулдаг вэ?” “Хөдөлмөрийн харилцаанд ялгаварлан гадуурхалт юу гэж юу вэ?”
Ажлын байрны дарамт	“Ажлын байран дээр дарамтад өртвөл хэнд хандах вэ?” “Бэлгийн дарамт гэдэг ойлголтыг тайлбарлана уу.”
Сургуулийн дээрэлхэлт	“Сургууль дээрээ дээрэлхүүлвэл яах вэ?” “Намайг ангийнхан маань гадуурхдаг.”
Гэр бүлийн хүчирхийлэл	“Гэр бүлийн хүчирхийлэлд өртсөн хүн хаашаа хандах вэ?” “Хүчирхийлэлд өртөгчийг хамгаалах хууль зүйн арга хэмжээ юу вэ?”
Crisis / эмзэг агуулга	“Би өөрийгөө гэмтээж байна.” “Тэсэхгүй байна, зүгээр л үхмээр байна.”

Хүснэгт А.1: Туршилтын асуултын сэдэв бүрийн жишээ багц

А.4 Эх кодын байршил

Системийн эх код Git-ээр хувилбарлагдан хадгалагдаж байна. Кодын үндсэн модулиудын байршил:

- `backend/app/`: FastAPI application, services, API routes, DB
- `rag/`: Retrieval-Augmented Generation pipeline (ingestion, chunker, vector store, generator)
- `frontend/`: React + Vite suuriltai chat UI
- `data/raw/`: Мэдлэгийн санд оруулсан баримтууд
- `data/vectors/chroma/`: ChromaDB persistent storage
- `tests/`: pytest-д суурилсан нэгж шалгалт

Ном зүй

- [1] UN Women. *Women's Economic Empowerment*. Official UN Women resource. 2026. URL: <https://knowledge.unwomen.org/en/topics/womens-economic-empowerment> (urlseen 10/03/2026).
- [2] United Nations Department of Economic and Social Affairs. *Social Inclusion*. Official UN DESA resource. 2026. URL: <https://social.desa.un.org/issues/social-inclusion> (urlseen 10/03/2026).
- [3] UNESCO. *What You Need to Know About School Violence and Bullying*. Official UNESCO article. 2020. URL: <https://www.unesco.org/en/articles/what-you-need-know-about-school-violence-and-bullying> (urlseen 10/03/2026).
- [4] World Economic Forum. *Global Gender Gap Report 2023*. Official annual report. World Economic Forum, 2023. URL: <https://www.weforum.org/reports/global-gender-gap-report-2023/>.
- [5] World Health Organization. *Violence Against Women Prevalence Estimates, 2018*. Official WHO report. World Health Organization, 2021. URL: <https://www.who.int/publications/i/item/9789240022256>.
- [6] UN Women. *Facts and Figures: Ending Violence Against Women*. Official UN Women resource. 2024. URL: <https://www.unwomen.org/en/what-we-do/ending-violence-against-women/facts-and-figures> (urlseen 10/04/2026).
- [7] UNICEF Mongolia. *Хүүхдийн эсрэг хучирхийллийн нөхцөл байдлын судалгаа*. Official UNICEF Mongolia publication. UNICEF Mongolia, 2022. URL: <https://www.unicef.org/mongolia/>.
- [8] Үндэсний статистикийн хороо. *Хүйсийн тэгш байдлын статистик үзүүлэлт*. Албан ёсны статистикийн мэдээллийн сан, Монгол Улс. 2024. URL: <https://www.1212.mn/> (urlseen 10/04/2026).

- [9] Монгол Улсын Хүний эрхийн Үндэсний Комисс. *Хүний эрхийн төлөв байдлын тухай илтгэл*. Албан ёсны илтгэл. 2023. URL: <https://nhrcm.gov.mn/> (*urlseen* 10/04/2026).
- [10] Ashish Vaswani **and others**. “Attention Is All You Need”. in *Advances in Neural Information Processing Systems*: **volume** 30. 2017.
- [11] Jacob Devlin **and others**. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. in *Proceedings of NAACL-HLT: 2019*, **pages** 4171–4186.
- [12] Colin Raffel **and others**. “Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer”. in *Journal of Machine Learning Research*: 21.140 (2020), **pages** 1–67.
- [13] Tom B. Brown **and others**. “Language Models are Few-Shot Learners”. in *Advances in Neural Information Processing Systems*: **volume** 33. 2020, **pages** 1877–1901.
- [14] Long Ouyang **and others**. “Training Language Models to Follow Instructions with Human Feedback”. in *Advances in Neural Information Processing Systems*: **volume** 35. 2022, **pages** 27730–27744.
- [15] Emily M. Bender **and others**. “On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?” in *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*: 2021, **pages** 610–623. DOI: 10.1145/3442188.3445922.
- [16] Ziwei Ji **and others**. “Survey of Hallucination in Natural Language Generation”. in *ACM Computing Surveys*: 55.12 (2023), **pages** 1–38. DOI: 10.1145/3571730.
- [17] Lei Huang **and others**. “A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions”. in *ACM Transactions on Information Systems*: (2024). DOI: 10.1145/3703155.
- [18] Gemini Team, Google. “Gemini: A Family of Highly Capable Multimodal Models”. in *arXiv preprint arXiv:2312.11805*: (2023).
- [19] Eleni Adamopoulou **and** Lefteris Moussiades. “An Overview of Chatbot Technology”. in *Artificial Intelligence Applications and Innovations*: Springer, 2020, **pages** 373–383. DOI: 10.1007/978-3-030-49186-4_31.
- [20] Patrick Lewis **and others**. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. in *Advances in Neural Information Processing Systems*: **volume** 33. 2020, **pages** 9459–9474.

- [21] Gautier Izacard **and** Edouard Grave. “Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering”. *in arXiv preprint arXiv:2007.01282*: (2020).
- [22] Chroma. *Chroma: The Open-Source Embedding Database*. Official documentation. 2024. URL: <https://docs.trychroma.com/> (**urlseen** 15/04/2026).
- [23] Microsoft. *Responsible AI Principles and Approach*. Official Microsoft guidance. 2026. URL: <https://www.microsoft.com/en/ai/principles-and-approach> (**urlseen** 10/03/2026).
- [24] National Institute of Standards and Technology. *AI Risk Management Framework (AI RMF 1.0)*. Official NIST publication. 2023. URL: <https://www.nist.gov/itl/ai-risk-management-framework> (**urlseen** 15/04/2026).
- [25] European Parliament. *EU AI Act: First Regulation on Artificial Intelligence*. Official European Parliament news article. 2024. URL: <https://www.europarl.europa.eu/topics/en/article/20230601ST093804/eu-ai-act-first-regulation-on-artificial-intelligence> (**urlseen** 15/04/2026).
- [26] Монгол Улсын Их Хурал. *Жендэрийн эрх тэгш байдлыг хангах тухай хууль*. Албан ёсны эрх зүйн мэдээллийн сан. 2011. URL: <https://legalinfo.mn> (**urlseen** 10/03/2026).
- [27] Монгол Улсын Их Хурал. *Хөдөлмөрийн тухай хууль*. Албан ёсны эрх зүйн мэдээллийн сан. 2021. URL: <https://legalinfo.mn> (**urlseen** 10/03/2026).
- [28] International Labour Organization. *Convention No. 111: Discrimination (Employment and Occupation) Convention*. Official convention text. 1958. URL: <https://www.ilo.org> (**urlseen** 10/03/2026).
- [29] ServiceNow. *Virtual Agent for HR Service Delivery*. Official documentation. 2026. URL: <https://www.servicenow.com/docs/r/employee-service-management/hr-service-delivery/hr-virtual-agent-conversations.html> (**urlseen** 20/03/2026).
- [30] Microsoft. *Enhance AI Responses with Retrieval Augmented Generation*. Official documentation. 2026. URL: <https://learn.microsoft.com/en-us/microsoft-copilot-studio/guidance/retrieval-augmented-generation> (**urlseen** 20/03/2026).
- [31] Government Digital Service. *Using Chatbots and Webchat Tools*. Official guidance. 2020. URL: <https://www.gov.uk/guidance/using-chatbots-and-webchat-tools> (**urlseen** 20/03/2026).

- [32] Nils Reimers **and** Iryna Gurevych. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”. *in Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*: 2019, **pages** 3982–3992. DOI: 10.18653/v1/D19-1410.
- [33] Vladimir Karpukhin **and others**. “Dense Passage Retrieval for Open-Domain Question Answering”. *in Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*: 2020, **pages** 6769–6781.
- [34] Jianlv Chen **and others**. “BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation”. *in arXiv preprint arXiv:2402.03216*: (2024).
- [35] Shitao Xiao **and others**. “C-Pack: Packaged Resources To Advance General Chinese Embedding”. *in arXiv preprint arXiv:2309.07597*: (2023).
- [36] Shahul Es **and others**. “RAGAS: Automated Evaluation of Retrieval Augmented Generation”. *in Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*: 2024, **pages** 150–158.
- [37] Google. *Gemini API Documentation*. Official documentation. 2026. URL: <https://ai.google.dev/gemini-api/docs> (**urlseen** 15/04/2026).
- [38] Meta Open Source. *React: The Library for Web and Native User Interfaces*. Official documentation. 2024. URL: <https://react.dev/> (**urlseen** 15/04/2026).
- [39] Vite. *Vite: Next Generation Frontend Tooling*. Official documentation. 2024. URL: <https://vitejs.dev/> (**urlseen** 15/04/2026).
- [40] Sebastián Ramírez. *FastAPI: Modern, Fast (high-performance) Web Framework for Building APIs with Python*. Official documentation. 2024. URL: <https://fastapi.tiangolo.com/> (**urlseen** 15/04/2026).
- [41] D. Richard Hipp. *SQLite: Self-Contained, Serverless, Zero-Configuration SQL Database Engine*. Official documentation. 2024. URL: <https://www.sqlite.org/> (**urlseen** 15/04/2026).